

神经拟态的类脑智能

中国科学院自动化研究所


吴高巍

gaowei.wu@ia.ac.cn

2016-12-20

从“联结主义”到“类脑智能”

- 深度学习在视、听、说等方面取得的巨大成功掀起了类脑计算的新浪潮。
- 借助于 **Deep Learning** 算法，人类终于找到了如何处理“抽象概念”这个亘古难题的方法。



类脑智能的兴起

■ 原由

■ 从计算机体系结构的角度


- 由于传统半导体器件的尺寸逐渐接近其物理极限，摩尔定理难以为继，同时功耗问题也日渐突出。

■ 从智能信息处理的角度

- 人工智能虽然取得了很大进展，并在许多特定领域得到了广泛应用，但智能程度依然极为有限，与人的智能依然相差甚远，理论与方法上亟待出现新思路与新突破。

类脑智能的兴起

- 现有智能的不足
 - 综合能力差
 - 自主学习能力弱
 - 理解能力弱，鲁棒性差
- 深度神经网络依然有它的瓶颈
 - 训练效率问题
 - 不够鲁棒




类脑智能的兴起




IBM 深蓝电脑



IBM 沃森(Watson)



IBM 类脑模拟




谷歌大脑

类脑智能的兴起



Deep Mind



SPAUN



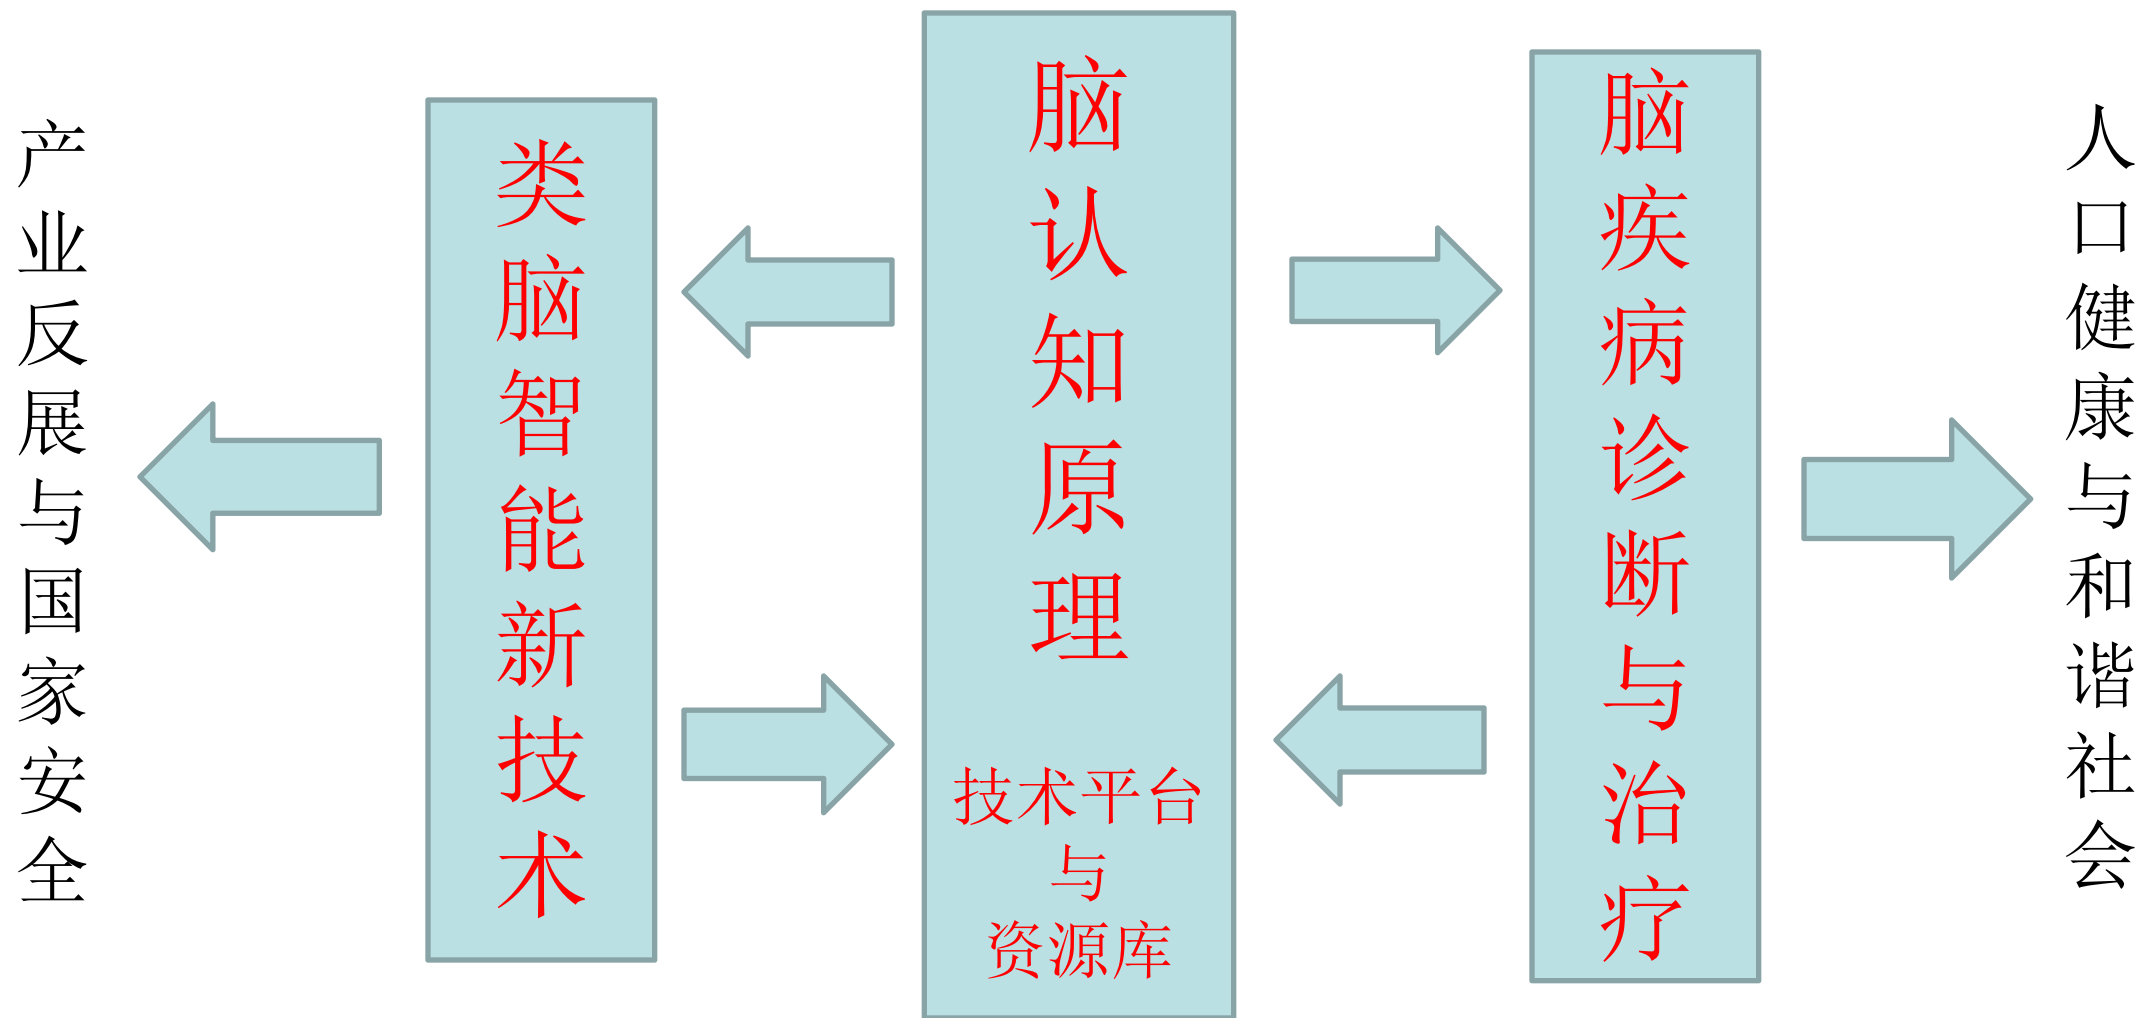
欧盟的“人类大脑计划”



美国的“大脑活动图谱计划”

中国脑计划

(十三五期间国家重大专项)



类脑智能研究

- 主要课题

- 如何从对大脑可塑性相当粗浅的理解中，抽取对类脑智能技术有启发的内容

- 研究核心

- 主要在于脑科学、计算科学、信息科学、医学等学科领域密集的交叉融合

- 技术支持

- 脑认知科学等进展丰富了对大脑的认识；
- 大数据提供了丰富的训练样本；
- 计算能力的提升促进了大规模模拟；
- 集成电路等领域突破奠定硬件基础。

人工智能的发展方向：类脑智能


- 通过类脑神经机理的模拟与实现达到类人行为上的机器智能
 - 从实现机理上采用类脑神经网络
 - 网络结构、脑区、神经元功能上模拟脑
 - 从单任务向多任务、多通道、多脑区协同处理发展
- 通过与现实世界持续交互、自主学习和演化，实现类人智能
 - 多模态协同和与非结构化数据的交互式学习自主能力
 - 复杂单任务能力到自主多任务协同演化的智能系统
 - 能自行解决问题

类脑机理


类人智能行为

类脑是手段，智能是目标

脉冲神经网络(Spiking neural networks)

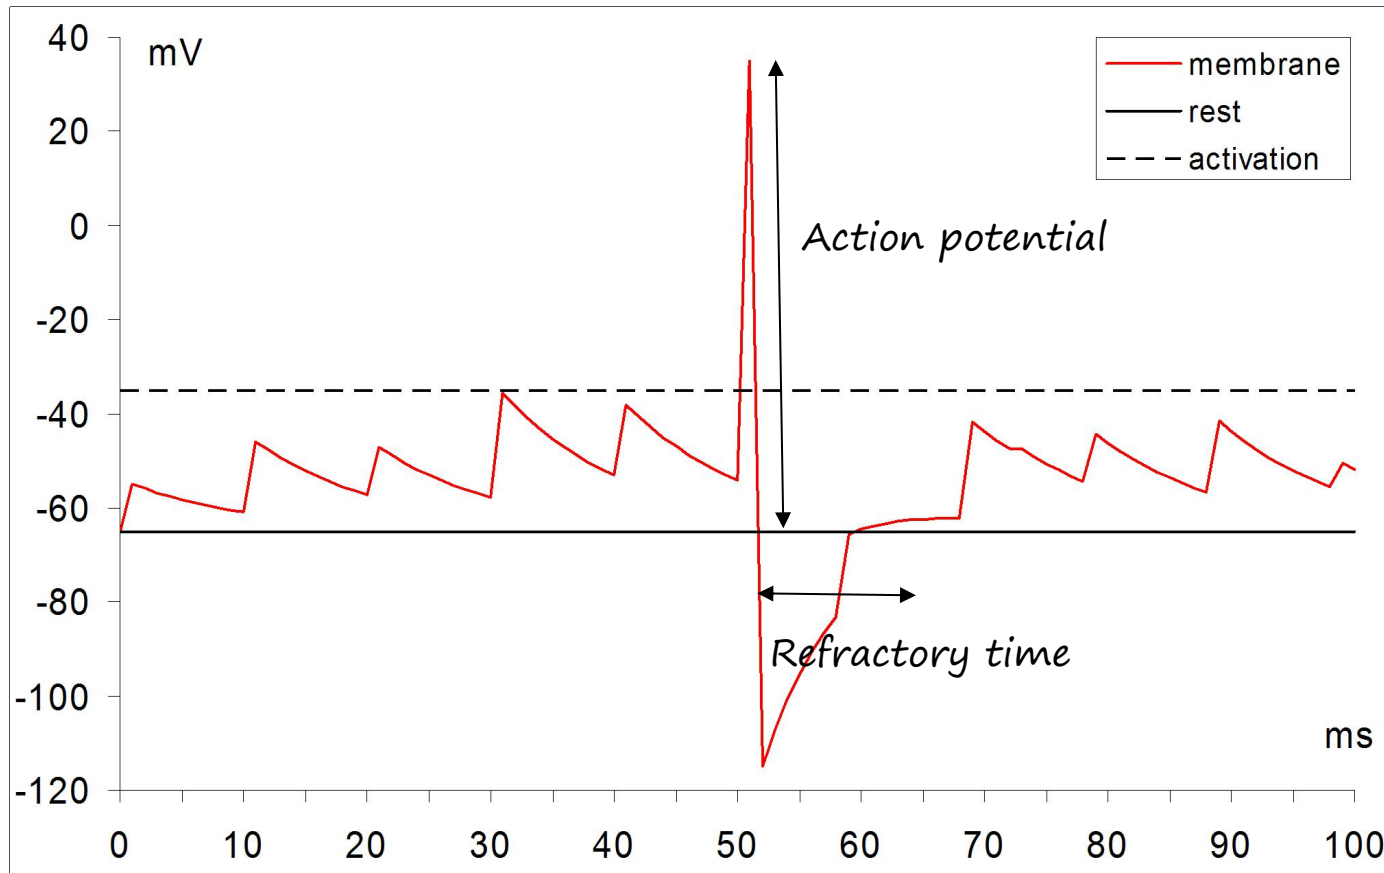


生物神经元




- 神经元组成：细胞体，轴突，树突，突触
- 神经元之间通过突触两两相连。信息的传递发生在突触。
- 突触记录了神经元间联系的强弱。
- 只有达到一定的兴奋程度，神经元才向外界传输信息。

Neural Dynamics



Action potential $\approx 100\text{mV}$
Activation threshold $\approx 20\text{-}30\text{mV}$
Rest potential $\approx -65\text{mV}$
Spike time $\approx 1\text{-}2\text{ms}$
Refractory time $\approx 10\text{-}20\text{ms}$


Binary Neurons



<i>Stimulus</i>	<i>Response</i>
$u_i = \sum_j w_{ij} \cdot x_j$	$y_i = f(u_{rest} + u_i)$
<p><i>“Hard” threshold</i></p> $f(z) = \begin{cases} z \geq \Theta \Rightarrow ON \\ else \Rightarrow OFF \end{cases} \quad \Theta = \text{threshold}$	

- ex: Perceptrons, Hopfield NNs, Boltzmann Machines
- Main drawbacks: can only map binary functions, biologically implausible.

Analog Neurons



Stimulus

$$u_i = \sum_j w_{ij} \cdot x_j$$

Response

$$y_i = f(u_{rest} + u_i)$$

“Soft” threshold

$$f(z) = \frac{2}{1 + e^{-z}} - 1$$

- ex: MLPs, Recurrent NNs, RBF NNs...
- Main drawbacks: difficult to process time patterns, biologically implausible.

Spiking Neurons

Stimulus

$$u_i(t) = \sum_j w_{ij} \cdot x_j(t)$$


Response

$$y_i(t) = f\left(u_{rest} + \eta(t - t_f) + \sum_{\tau=0}^t \varepsilon(t, u_i(\tau))\right)$$

$$f(z) = \left\{ \begin{array}{l} z \geq \Theta \ \& \ \frac{dz}{dt} > 0 \Rightarrow ON \\ else \Rightarrow OFF \end{array} \right\}$$

η = spike and afterspike potential
 u_{rest} = resting potential
 $\varepsilon(t, u(\tau))$ = trace at time t of input at time τ
 Θ = threshold
 $x_j(t)$ = output of neuron j at time t
 w_{ij} = efficacy of synapse from neuron i to neuron j
 $u(t)$ = input stimulus at time t

Spiking Neuron Dynamics



spike response model, SRM

- the spike-train of a neuron

$$F = \{t^{(1)}, \dots, t^{(n)}\} = \{t \mid u_i(t) = \Theta \wedge u_i'(t) > 0\}$$


- model the refractoriness

$$\eta(s) = -n_0 \exp\left(-\frac{s - \delta^{abs}}{\tau}\right) H(s - \delta^{abs}) - KH(s)H(\delta^{abs} - s)$$

$$H(s) = \begin{cases} 1 & \text{if } s > 0 \\ 0 & \text{if } s \leq 0 \end{cases}$$

- effect of incoming postsynaptic potentials

$$\varepsilon_{ij}(s) = \left[\exp\left(-\frac{s - \Delta^{ij}}{\tau_s}\right) - \exp\left(-\frac{s - \Delta^{ij}}{\tau_f}\right) \right] H(s - \Delta^{ij})$$



spike response model, SRM

- The current excitation of a neuron

$$u_i(t) = \sum_{t_i^{(f)} \in F_i} \eta(t - t_i^{(f)}) + \sum_{j \in \Gamma_i} \sum_{t_j^{(f)} \in F_j} w_{ij} \mathcal{E}(t - t_j^{(f)})$$

- Short-term memory neurons




- only takes the refractory effects of the last pulse sent into account.

$$u_i(t) = \eta(t - t_i') + \sum_{j \in \Gamma_i} \sum_{t_j^{(f)} \in F_j} w_{ij} \mathcal{E}(t - t_j^{(f)})$$

Presynaptic
Output Spike
Train

Internal State
(Postsynaptic
Neuron)

Postsynaptic
Output Spike
Train



Leaky Integrate-and-Fire (LIF) Model

$$I(t) = \frac{u(t)}{R} + C \frac{du}{dt}$$




$$\tau_m \frac{du}{dt} = -u(t) + RI(t)$$

a 'firing-time' $t^{(f)} : u(t^{(f)}) = \vartheta$


$$\lim_{t \rightarrow t^{(f)}, t > t^{(f)}} u(t) = u_{rest}$$

$$I_{syn}(t) = \sum_i w_i I_{PSC}^i(t)$$

$$I_{PSC}^i(t) = \sum_{t^j} V_0 \left[\exp\left(-\frac{t-t^j}{\tau_s}\right) - \exp\left(-\frac{t-t^j}{\tau_f}\right) \right] H(t-t^j)$$





LIF

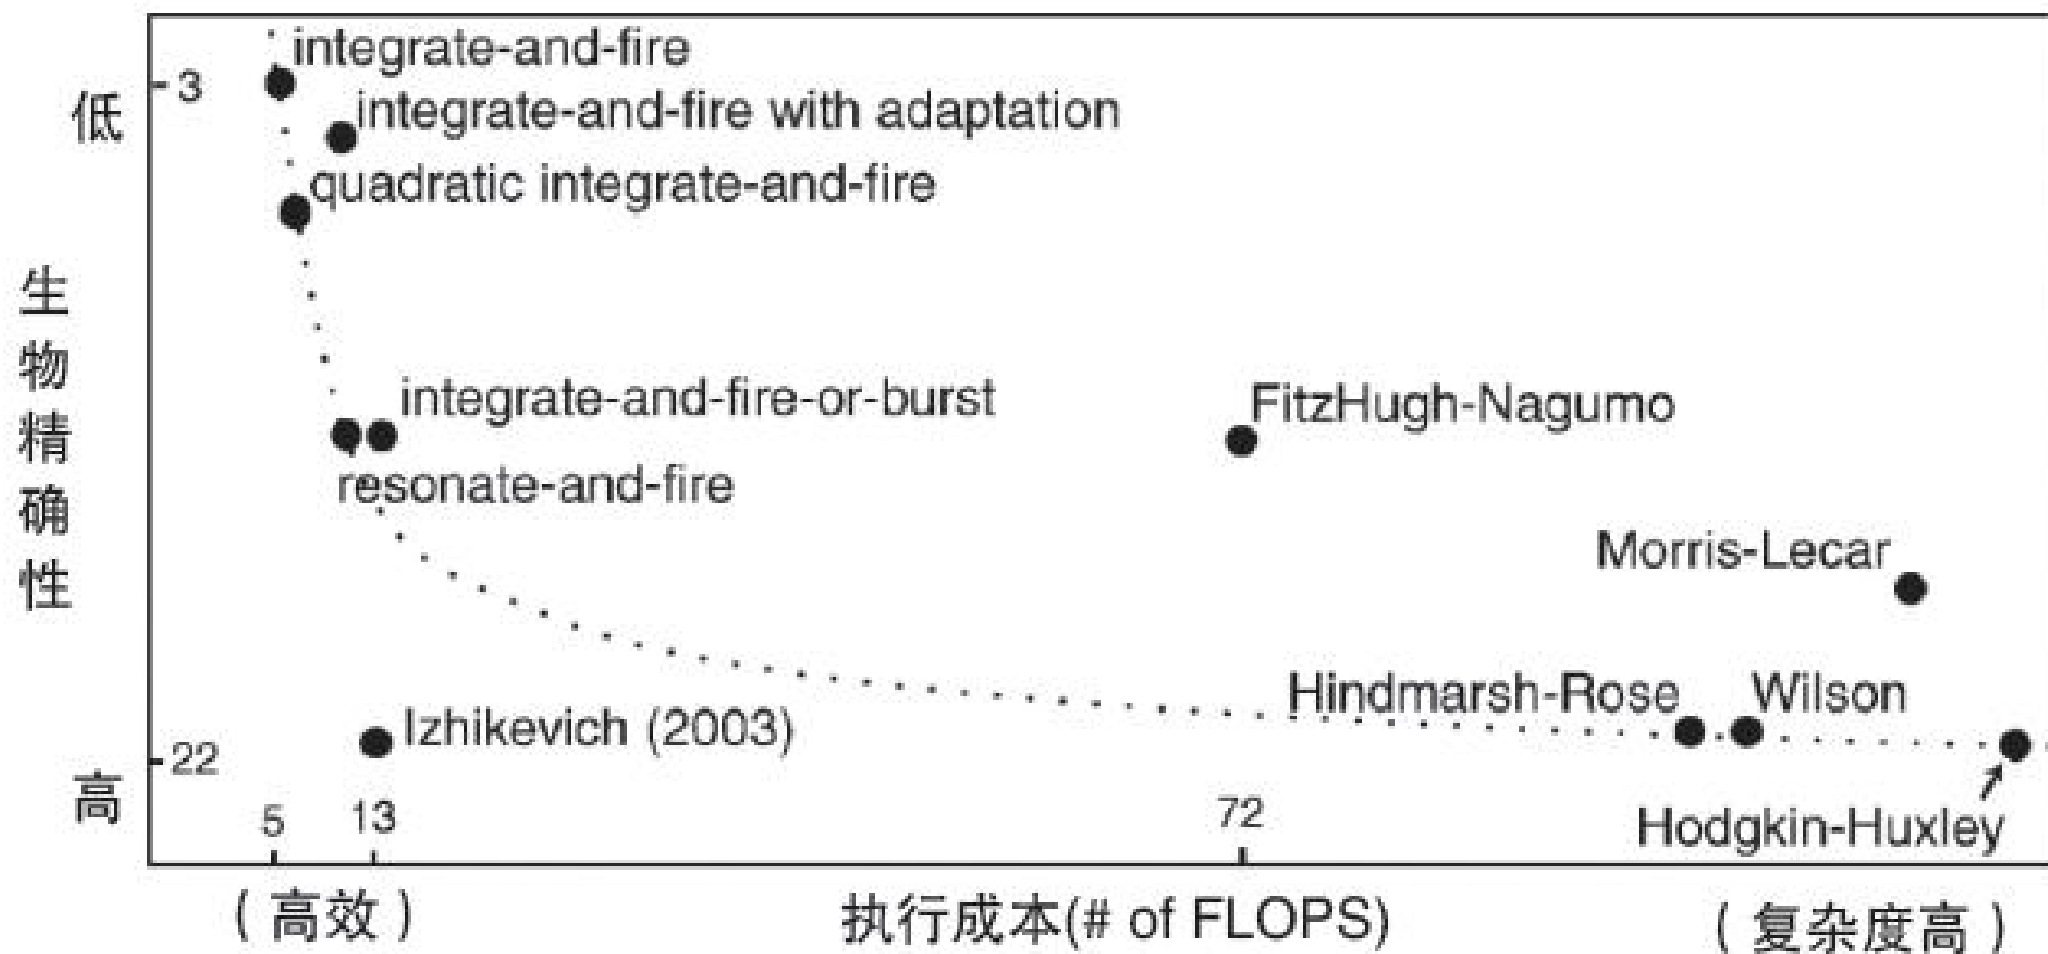


Hodgkin-Huxley(HH)模型

- HH 模型是一组描述神经元细胞膜的电生理现象的非线性微分方程

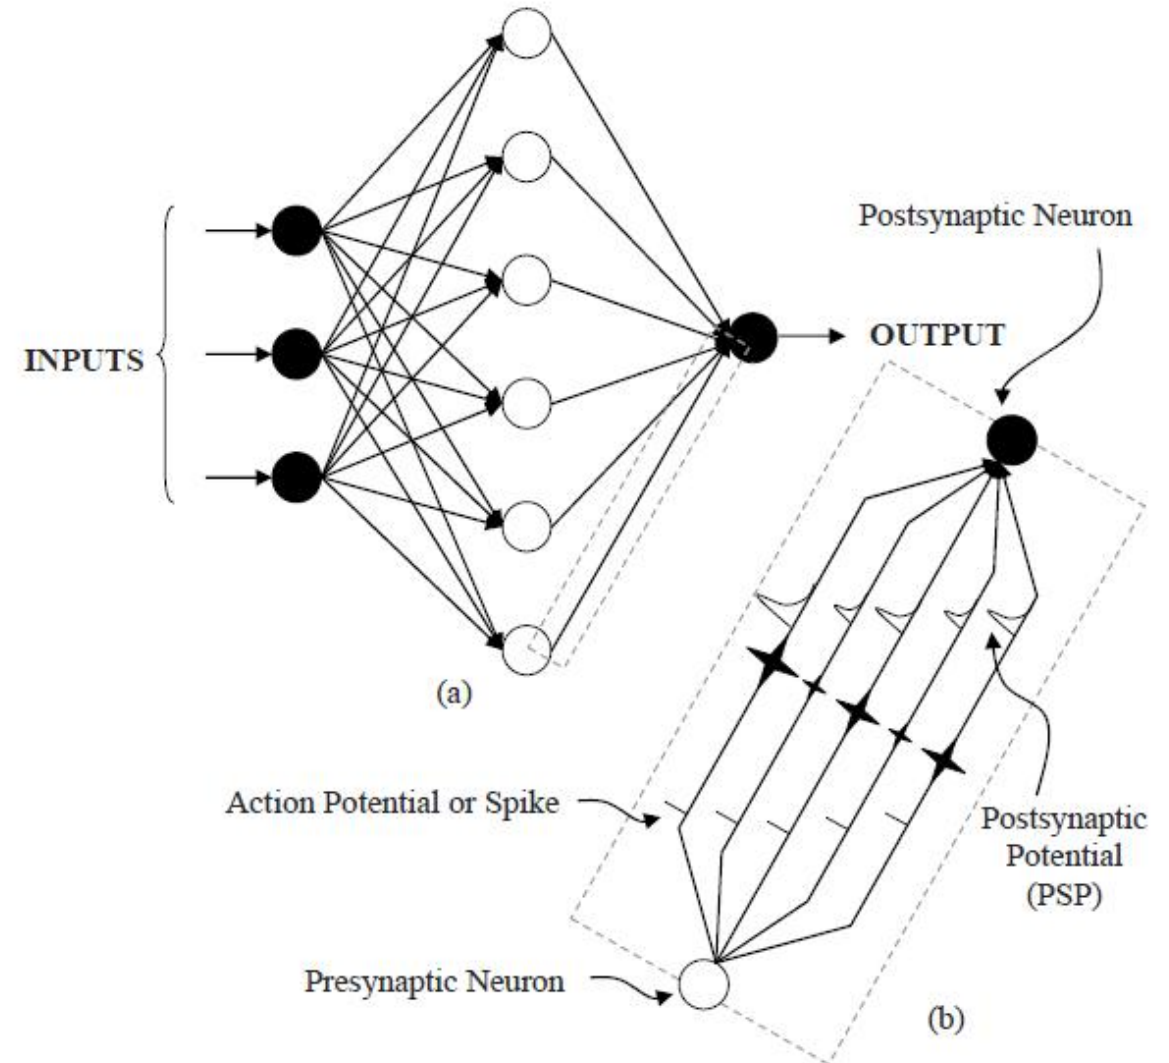


脉冲神经元模型



Spiking Neural Networks (SNNs)

- 由脉冲神经元构成的网络
 - The connection between two SNN neurons is modeled by multiple (K) synapses



脉冲神经网络的学习算法

- 非监督学习

- 基于赫布法则(Hebbian Rule)而设, STDP(Spike Timing Dependent Plasticity)
- “同时激发的神经元连接在一起”

- 监督学习

- 基于反向传播训练算法的思想, 从所犯的错误中学习
- Precise-Spike-Driven Synaptic Plasticity (PSD)
- 将传统的人工神经网络转化为脉冲神经网络的算法。


Precise-Spike-Driven Synaptic Plasticity (PSD)

- PSD Learning Rule

$$\begin{cases} s_i(t) = \sum_f \delta(t - t_i^f) \\ s_d(t) = \sum_g \delta(t - t_d^g) \\ s_o(t) = \sum_h \delta(t - t_o^h) \end{cases}$$

$$\frac{dw_i(t)}{dt} = \eta [s_d(t) - s_o(t)] I_{PSC}^i(t)$$

$$\Delta w_i = \eta x_i (y_d - y_o)$$

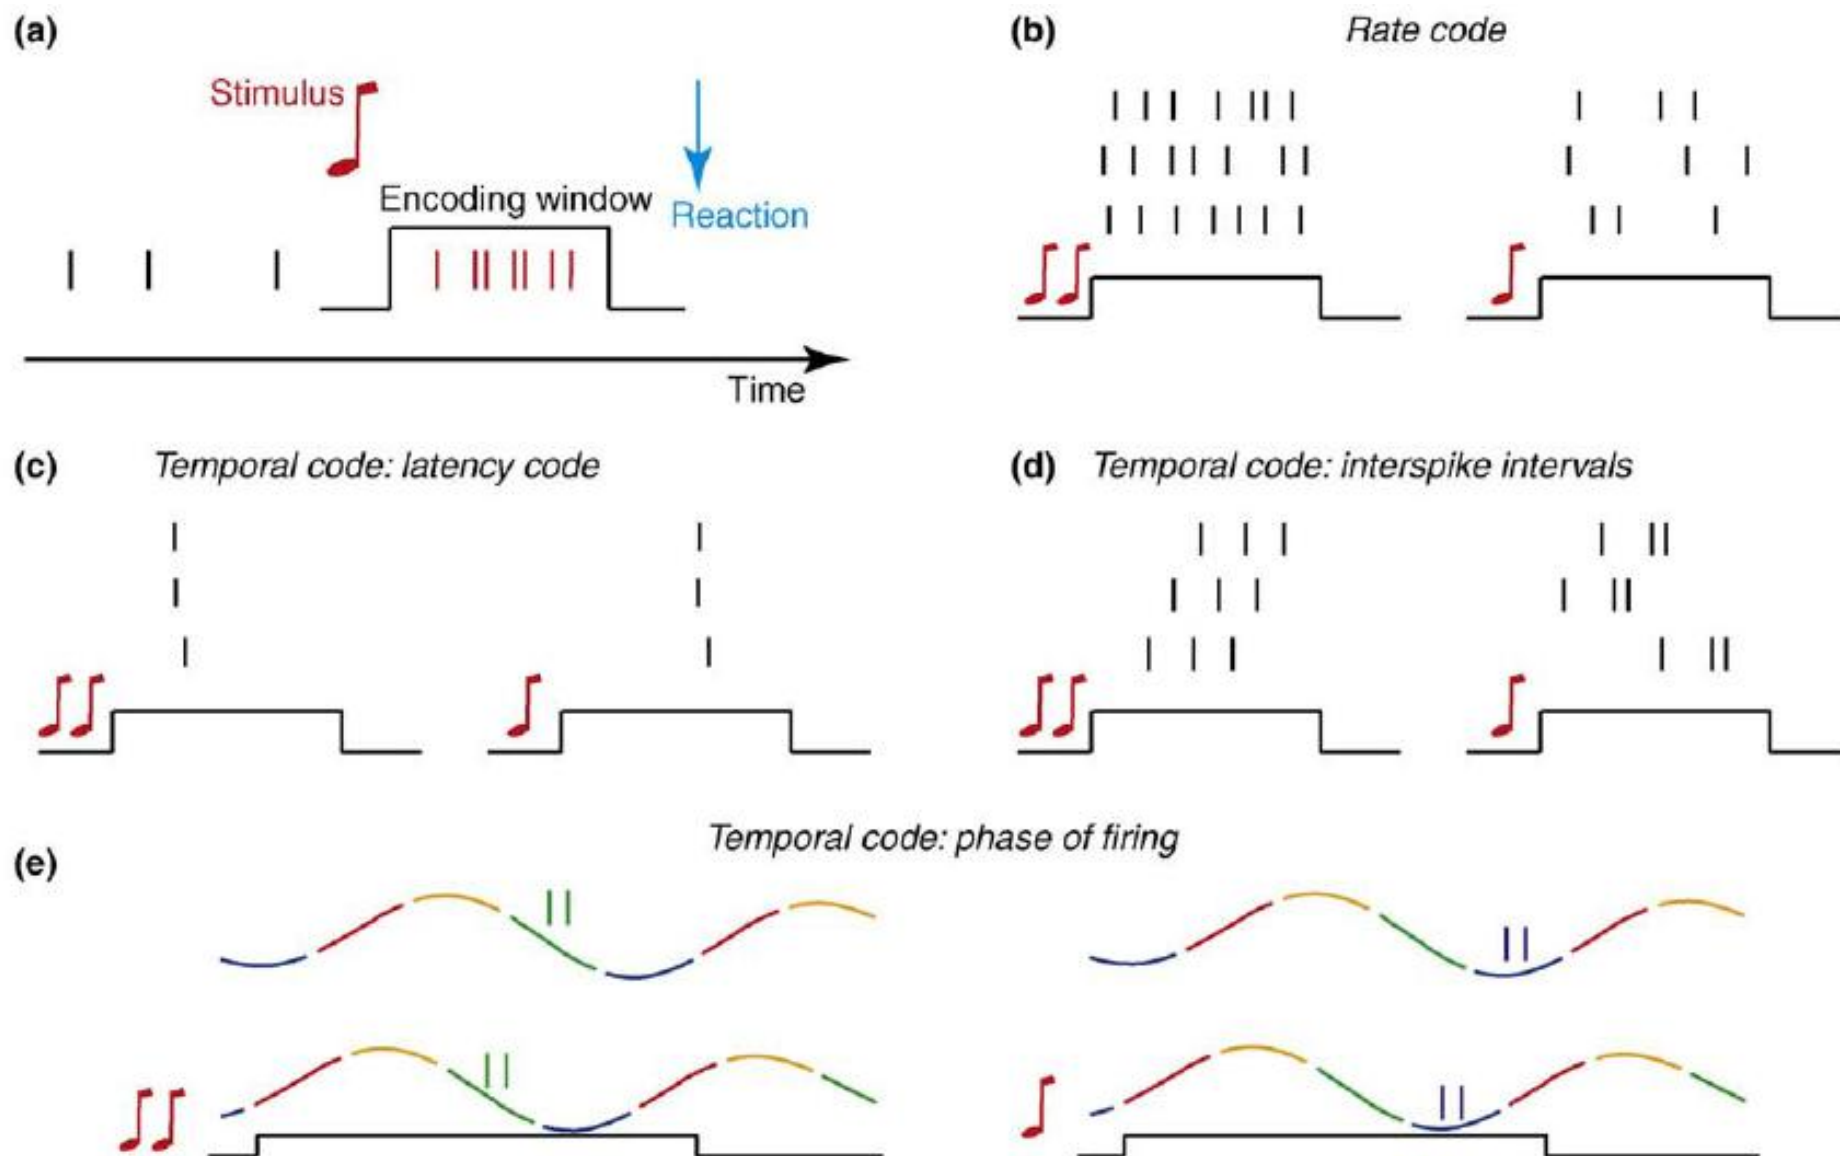


神经编码

■ 神经脉冲序


- 频率编码
 - 泊松过程
- 时间编码

■ 群体编码



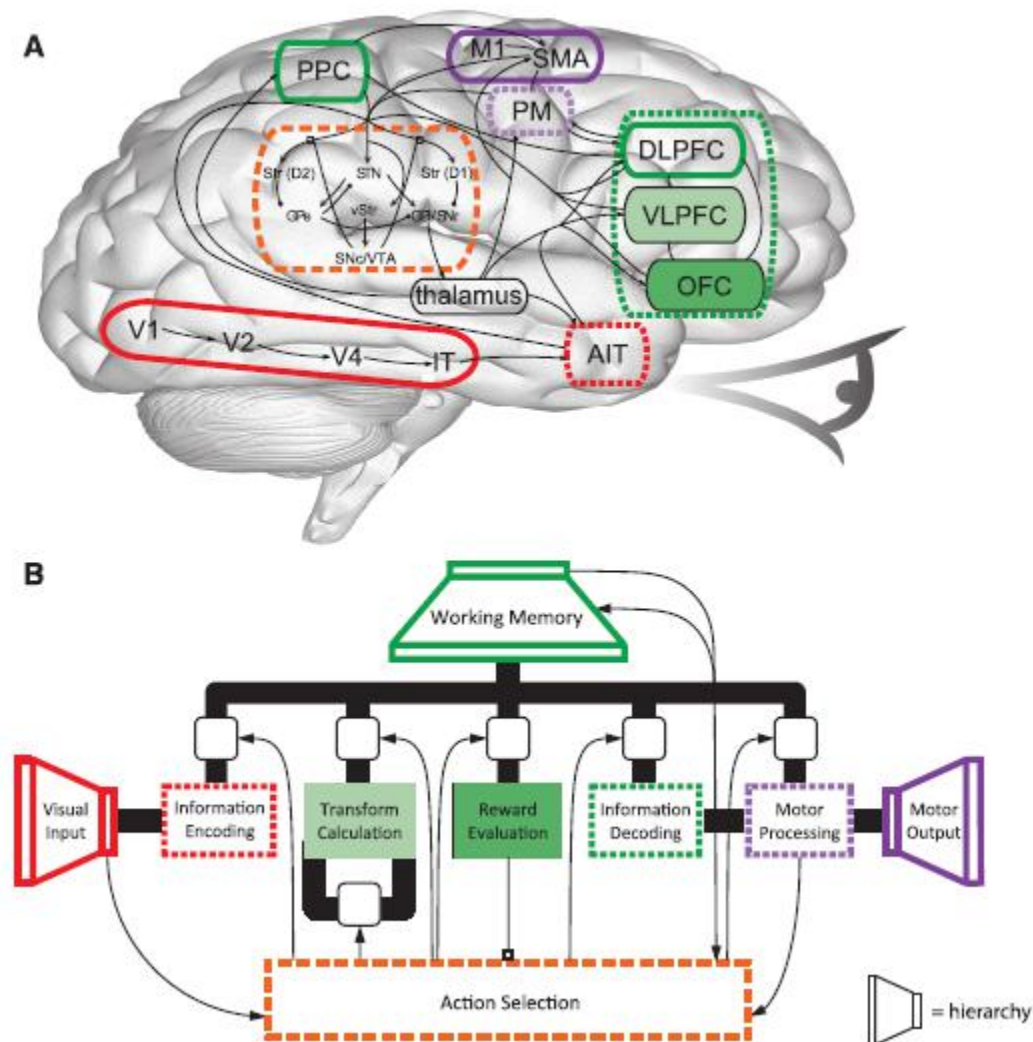
应用：模式识别

- 基于脉冲时间的模式识别模型
 - 主要由编码和学习网络两个部分组成
 - 编码部分采用将时滞编码和相位编码相结合的方法，以将图像信息转化为由神经脉冲序列组成的时空斑图(spatiotemporal pattern)。
 - 一个单层脉冲神经网络，用来学习识别不同的输入



应用：SPAUN

- Spaun (Semantic Pointer Architecture Unified Network, 语义指针架构统一网络)
 - 人类大脑模拟系统
 - 拥有**250万**只虚拟神经元，可以执行**8项**不同的任务。



小结

- 美国和欧盟启动脑科学和类脑工程项目使得“类脑智能”成为热门话题。
- 目前所谓的“类脑智能”与人脑相距甚远。
- 人工智能目前的重点是探索使机器体现智能行为的各种途径，研究开发智能化的设备和各种智能应用软件。
 - 智能是目标，类脑是手段

How to design computers?

Biological computer



Mathematical computer



- Which model to emulate : brain or mathematical logic ?
- Which will win?

References

- H Paugam-Moisy, S Bohte. Computing with Spiking Neuron Networks. Springer Verlag, 2012:335-376
- W. Gerstner, W. Kistler. Spiking Neuron Models . Cambridge University Press, 2002.
- Yu Q, Tang H, Tan K C, et al. Precise-spike-driven synaptic plasticity: Learning heteroassociation of spatiotemporal spike patterns[J]. 2013.
- Stefano Panzeri, Nicolas Brunel, Nikos K. Logothetis and Christoph Kayser. Sensory neural codes using multiplexed temporal scales. Trends in Neurosciences, 2009, vol. 33, no. 3, 111~120.
- J. Hu, H. Tang, K.C. Tan, H. Li, L. Shi. A Spike-Timing Based Integrated Model for Pattern Recognition. Neural Computation, 2013, vol. 25, no. 2, 450~472
- Eliasmith C, Stewart T C, Choo X, et al. A large-scale model of the functioning brain.[J]. Science, 2012, 338(6111):1202-5.

Thanks !