大数据系统与大规模数据分析

大数据运算系统（1）

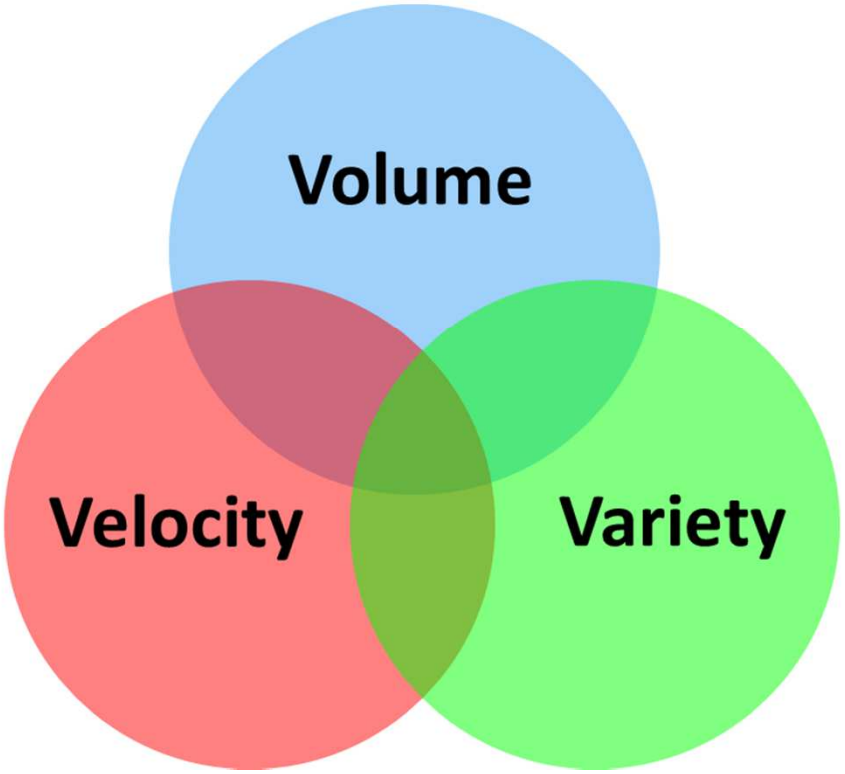

陈世敏

中科院计算所
计算机体系结构
国家重点实验室

Outline

- MapReduce/Hadoop
  - 编程模型
  - 系统实现
  - 典型算法
- Microsoft Dryad

MapReduce/Hadoop简介

- MapReduce是目前云计算中最广泛使用的计算模型
  - 由Google于2004年提出
  - "*MapReduce: Simplied Data Processing on Large Clusters*". Jeffrey Dean and Sanjay Ghemawat (Google). **OSDI 2004**.

- Hadoop是MapReduce的一个开源实现

  - 2005年由Doug Cutting and Mike Cafarella开始了Hadoop项目
  - 2006年Cutting成为Yahoo Lab的员工
  - Hadoop的开发主要由Yahoo Lab推动，后来成为Apache开源项目
  - 基于Java
  - 已经被广泛使用：Yahoo, Facebook, Twitter, Linkedin, Ebay, AOL, Hulu, 百度, 腾讯, 阿里, 天涯社区, ……

MapReduce编程模型

- 整体思路
- 数据模型
- Map-shuffle-Reduce
- Word count举例
- 与SQL Select语句的关系

整体思路

- 并行分布式程序设计不容易
  - Multi-threading
  - Socket programming
  - Data distribution
  - Job distribution, coordination, load balancing
  - Fault tolerance
  - Debugging
- 需要有经验的程序员+编程调试时间
  - 上面每个方面都需要学习和经验积累
  - 调试分布式系统很花时间和精力

整体思路

- 解决思路
  - 程序员写串行程序
  - 由系统完成并行分布式地执行

在本课中，程序员是指使用大数据平台实现上层应用功能的人员

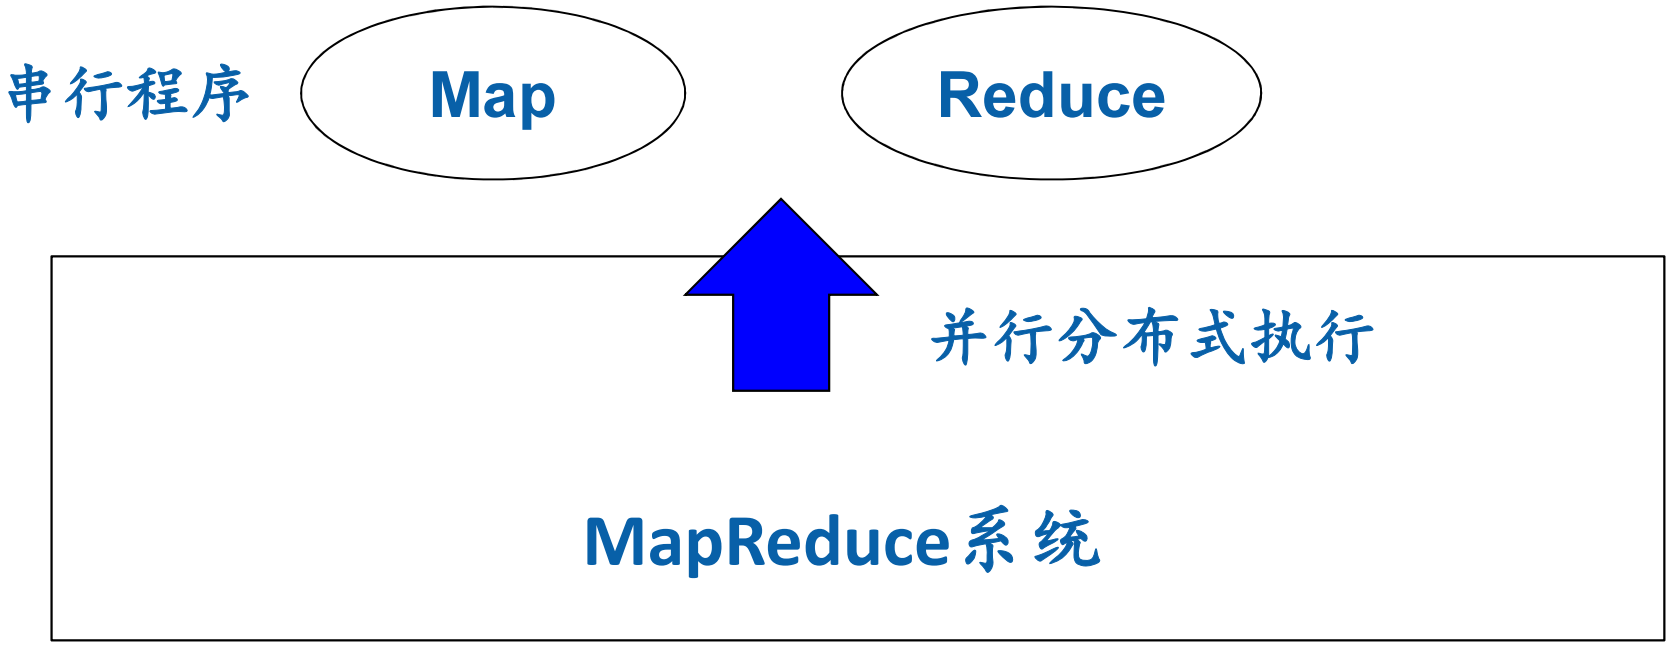

整体思路

- 解决思路
  - **程序员**写串行程序
  - 由**系统**完成并行分布式地执行
- 程序员保证串行程序的正确性
  - 编程序时不需要思考并行的问题
  - 调试时只需要保证串行执行正确
- 系统负责并行分布执行的正确性和效率
  - Multi-threading, Socket programming, Data distribution, Job distribution, coordination, load balancing, Fault tolerance
- 有什么问题吗？

整体思路

- 有什么问题吗？
- 牺牲了程序的功能！
  - 直接进行并行分布式编程，可以完成各种各样丰富的功能
  - 而一个编程模型实际上是限定了程序的功能类型
- 推论1：系统的编程模型必须有代表性
  - 必须代表一大类重要的应用才有生命力
- 推论2：一个成功的模型也就不可避免地被人们应用于原本不适合的情形
  - 需要扩展，需要新的模型
  - 这是后话

MapReduce的数据模型

- <key, value>
  - 数据由一条一条的记录组成
  - 记录之间是无序的
  - 每一条记录有一个key，和一个value
  - key: 可以不唯一
  - key与value的具体类型和内部结构由程序员决定，系统基本上把它们看作黑匣

MapReduce

Map(ik, iv) ➔{<mk, mv>}

Reduce(mk, {mv}) ➔{<ok, ov>}

Map函数

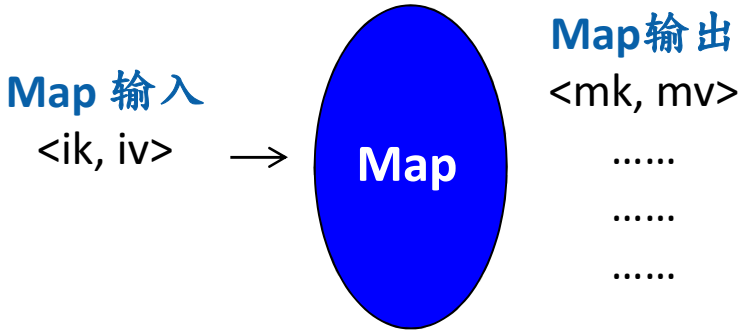

Map(ik, iv) ➔{<mk, mv>}

- 输入是一个key-value记录：<ik, iv>
  - 我们用’i’代表input
- 输出是0~多个key-value记录：<mk, mv>
  - 我们用’m’代表intermediate
- 注意：mk与ik很可能完全不同

Shuffle (由系统完成)

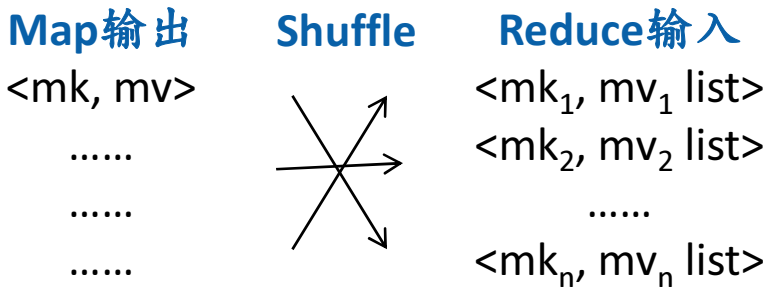

- Shuffle = group by mk
- 对于所有的map函数的输出，进行group by
- 将相同mk的所有mv都一起提供给Reduce

Reduce函数

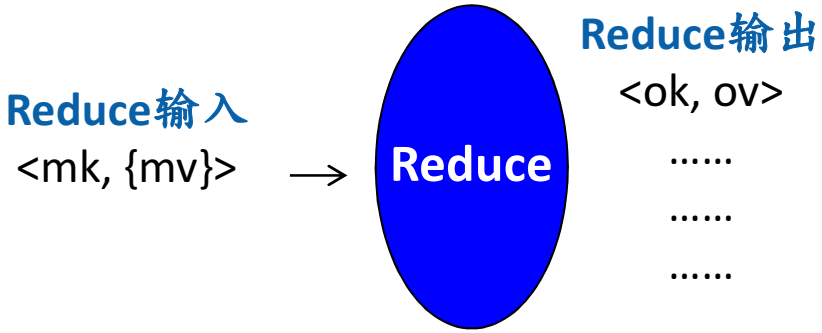

Reduce(mk, {mv}) ➔{<ok, ov>}

- 输入是一个mk和与之对应的所有mv
- 输出是0~多个key-value记录：<ok, ov>
  - 我们用’o’代表output
- 注意：ok与mk可能不同

Map-shuffle-Reduce

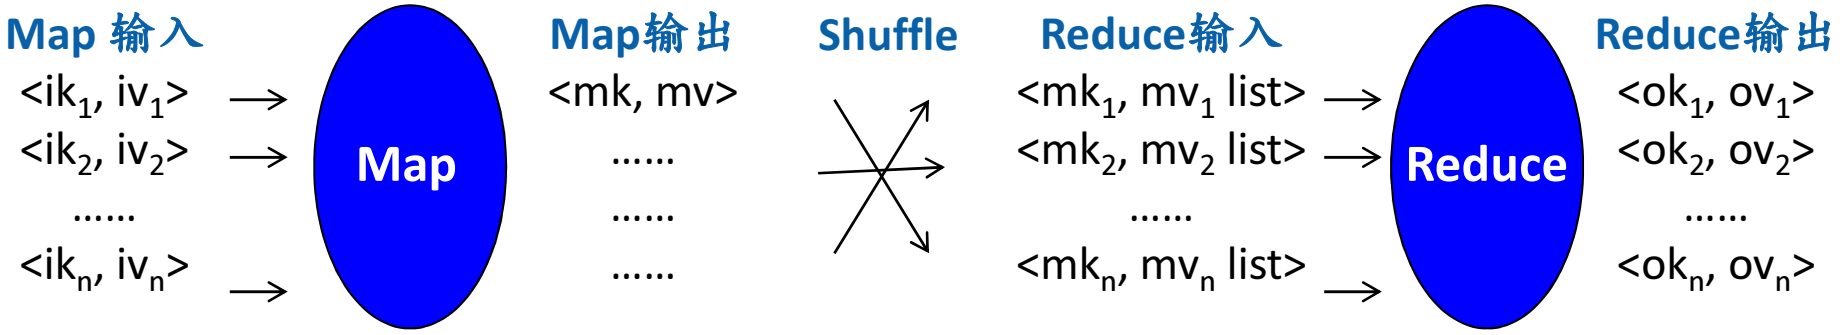

- 程序员编制串行的Map函数和Reduce函数
- 系统完成shuffle功能
  - shuffle = group by mk

Map-shuffle-Reduce： word count 举例

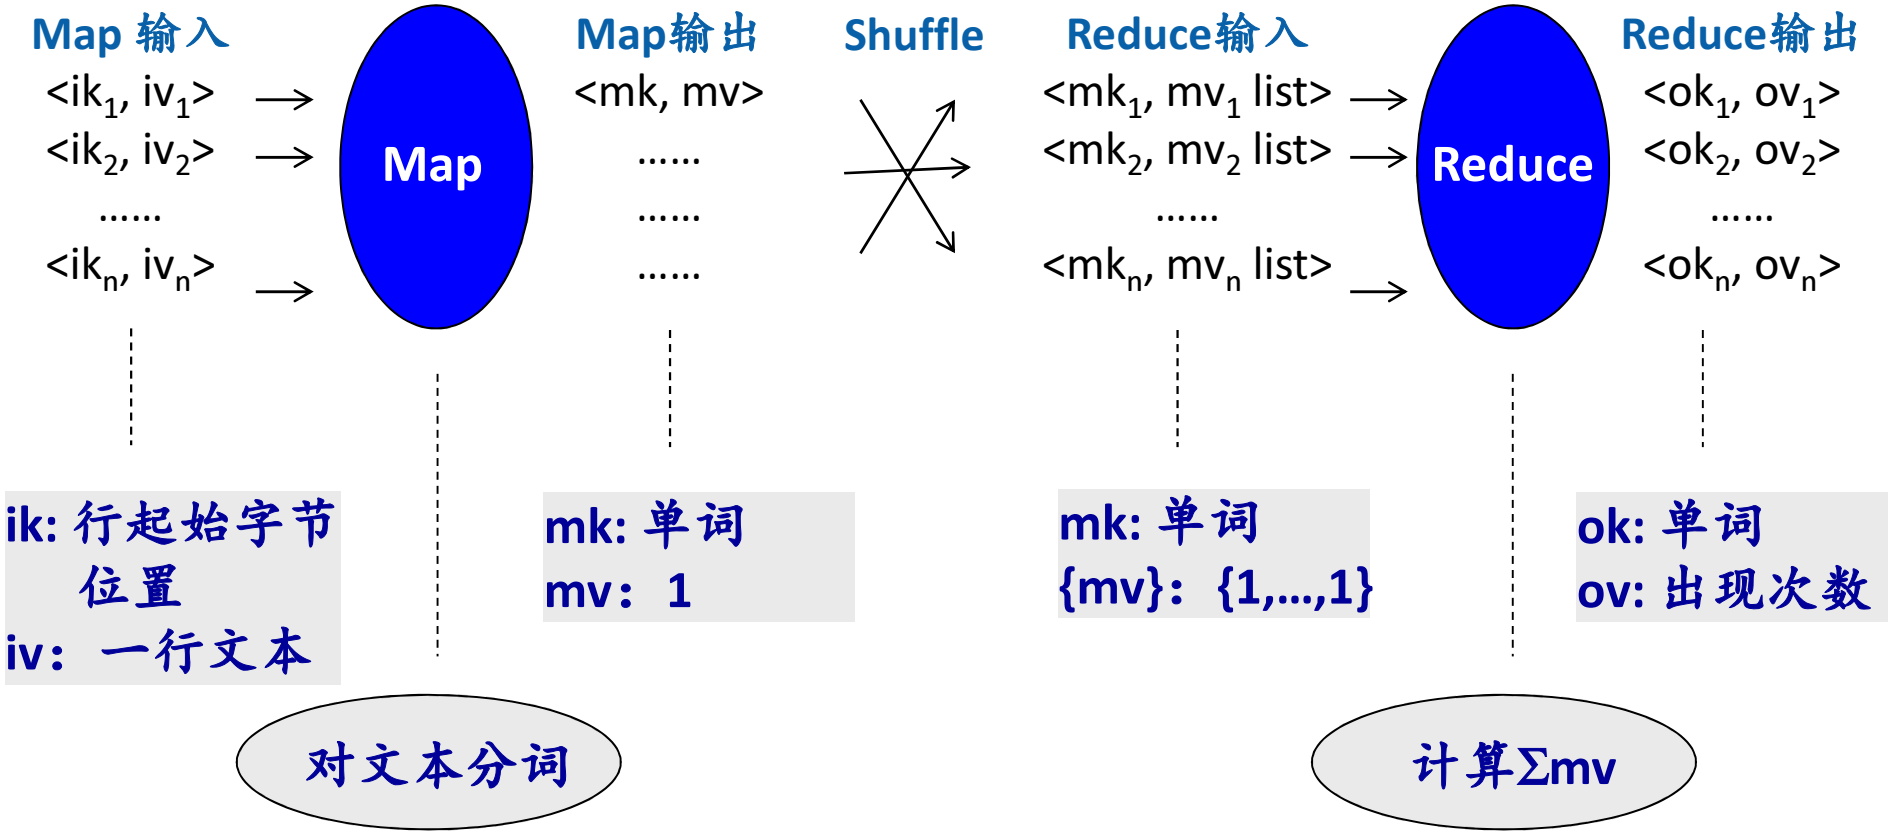

Word count: 统计文本中每个单词出现的次数

Hadoop Mapper.java （简化了exception handling）

```
public class Mapper<KEYIN, VALUEIN, KEYOUT, VALUEOUT> {
  protected void setup(Context context) {
    // NOTHING
  }
  protected void map(KEYIN key, VALUEIN value, Context context){
    context.write((KEYOUT) key, (VALUEOUT) value);
  }
  protected void cleanup(Context context) {
    // NOTHING
  }
  public void run(Context context) { //Hadoop调用run
    setup(context);
    while (context.nextKeyValue()) {
      map(context.getCurrentKey(), context.getCurrentValue(), context);
    }
    cleanup(context);
  }
}
```

Hadoop Reducer.java （简化了exception handling）

```
public class Reducer<KEYIN, VALUEIN, KEYOUT, VALUEOUT> {
  protected void setup(Context context) {
    // NOTHING
  }
  protected void reduce(
    KEYIN key, Iterable<VALUEIN> vlist, Context context) {
    for(VALUEIN v: vlist) context.write((KEYOUT)key, (VALUEOUT)v);
  }
  protected void cleanup(Context context) {
    // NOTHING
  }
  public void run(Context context) {//Hadoop调用run
    setup(context);
    while (context.nextKey()) {
      reduce(context.getCurrentKey(), context.getValues(), context);
    }
    cleanup(context);
  }
}
```


WordCount.java

```
public class WordCount {

  public static class TokenizerMapper
       extends Mapper<Object, Text, Text, IntWritable>{

    private final static IntWritable one = new IntWritable(1);
    private Text word = new Text();

    public void map(Object key, Text value, Context context
                    ) throws IOException, InterruptedException {
      StringTokenizer itr = new StringTokenizer(value.toString());
      while (itr.hasMoreTokens()) {
        word.set(itr.nextToken());
        context.write(word, one);
      }
    }
  }
```

WordCount.java

```
public static class IntSumReducer
      extends Reducer<Text,IntWritable,Text,IntWritable> {
   private IntWritable result = new IntWritable();

   public void reduce(Text key, Iterable<IntWritable> values,
                      Context context
                      ) throws IOException, InterruptedException {
     int sum = 0;
     for (IntWritable val : values) {
       sum += val.get();
     }
     result.set(sum);
     context.write(key, result);
   }
 }
```

WordCount.java

```
public static void main(String[] args) throws Exception {
   Configuration conf = new Configuration();
   String[] otherArgs = new GenericOptionsParser(conf,
                                    args).getRemainingArgs();
   if (otherArgs.length != 2) {
     System.err.println("Usage: wordcount <in> <out>");
     System.exit(2);
   }
   Job job = new Job(conf, "word count");
   job.setJarByClass(WordCount.class);
   job.setMapperClass(TokenizerMapper.class);
   job.setCombinerClass(IntSumReducer.class);
   job.setReducerClass(IntSumReducer.class);
   job.setOutputKeyClass(Text.class);
   job.setOutputValueClass(IntWritable.class);
   FileInputFormat.addInputPath(job, new Path(otherArgs[0]));
   FileOutputFormat.setOutputPath(job, new Path(otherArgs[1]));
   System.exit(job.waitForCompletion(true) ? 0 : 1);
 }
```

比较

MapReduce

- Map
- Shuffle
- Reduce
- 选择的功能更加丰富
  - 程序实现的
  - 类似最简单的SQL select
  - 但不支持join

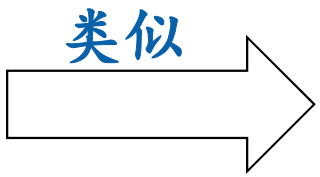

SQL Select

- Selection/projection
- Group by
- Aggregation, Having
- 功能由数据类型和SQL语言标准定义
  - 有UDF: user defined function
  - 但支持得不好

MapReduce系统架构

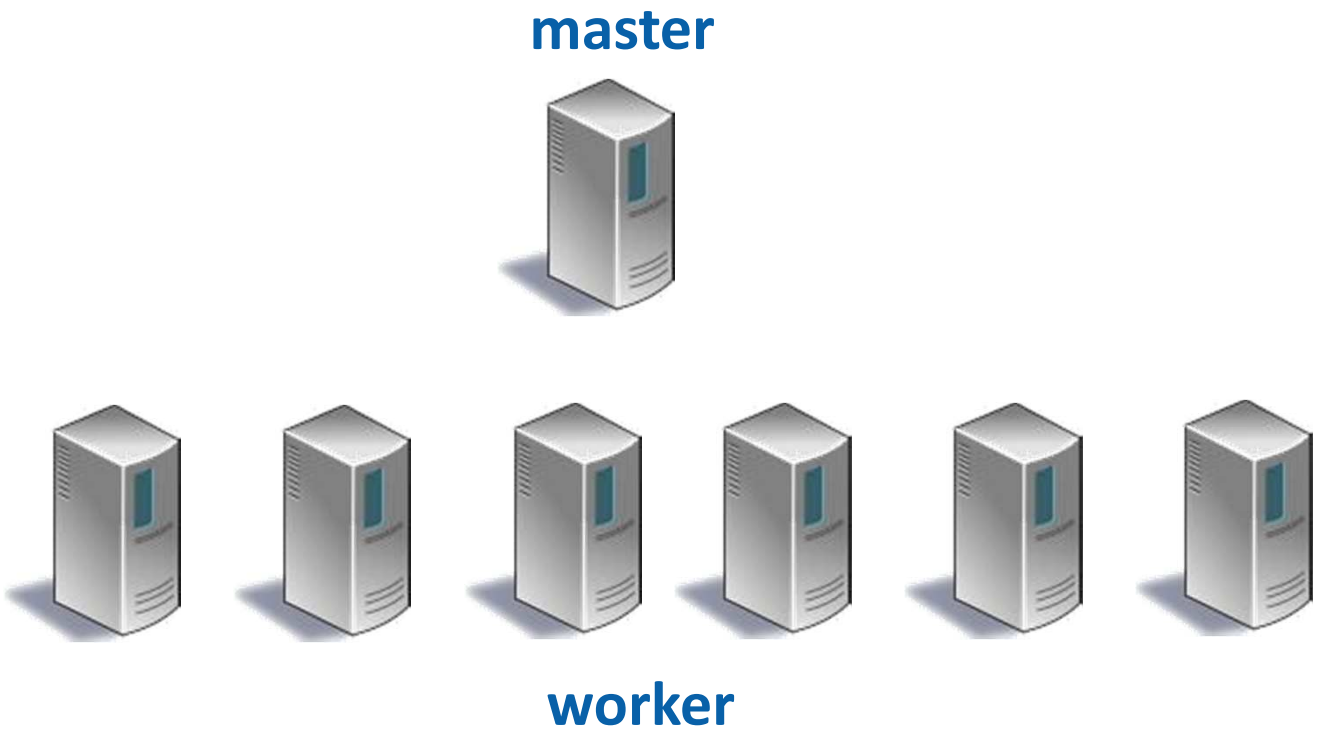

在OSDI'04文章中，基本上是1个master对应
100~1000数量级的workers

系统架构

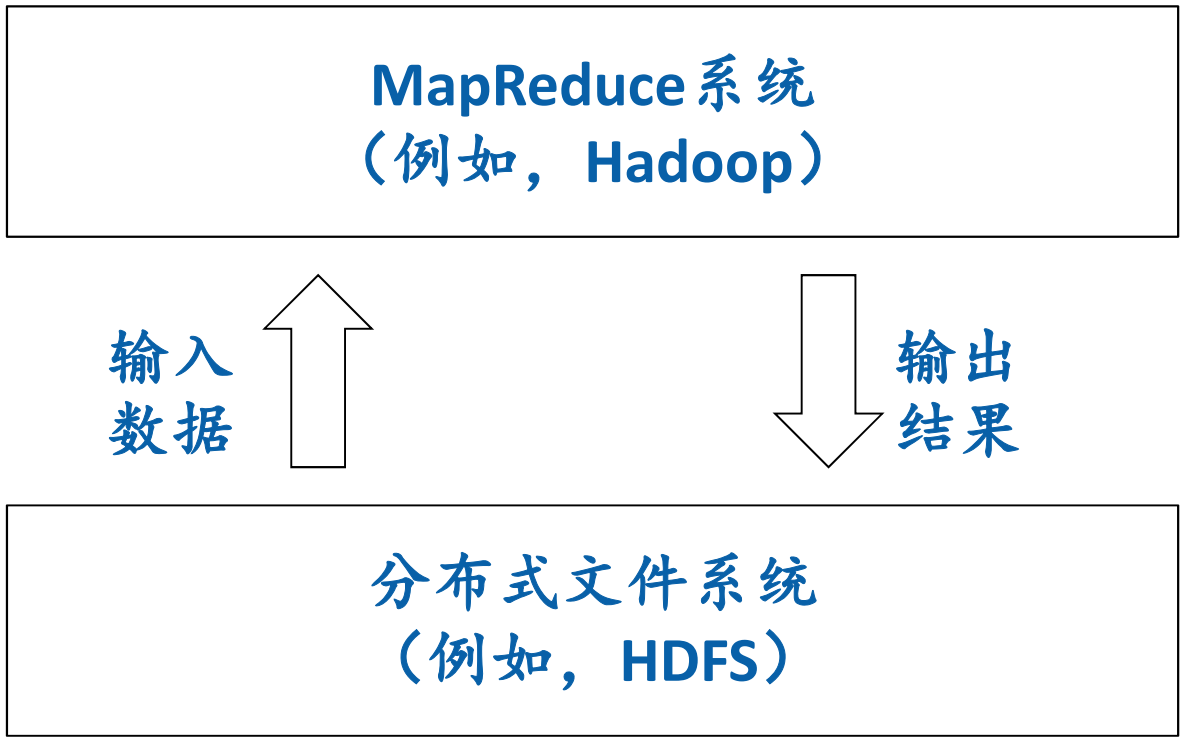

MapReduce / Hadoop系统架构

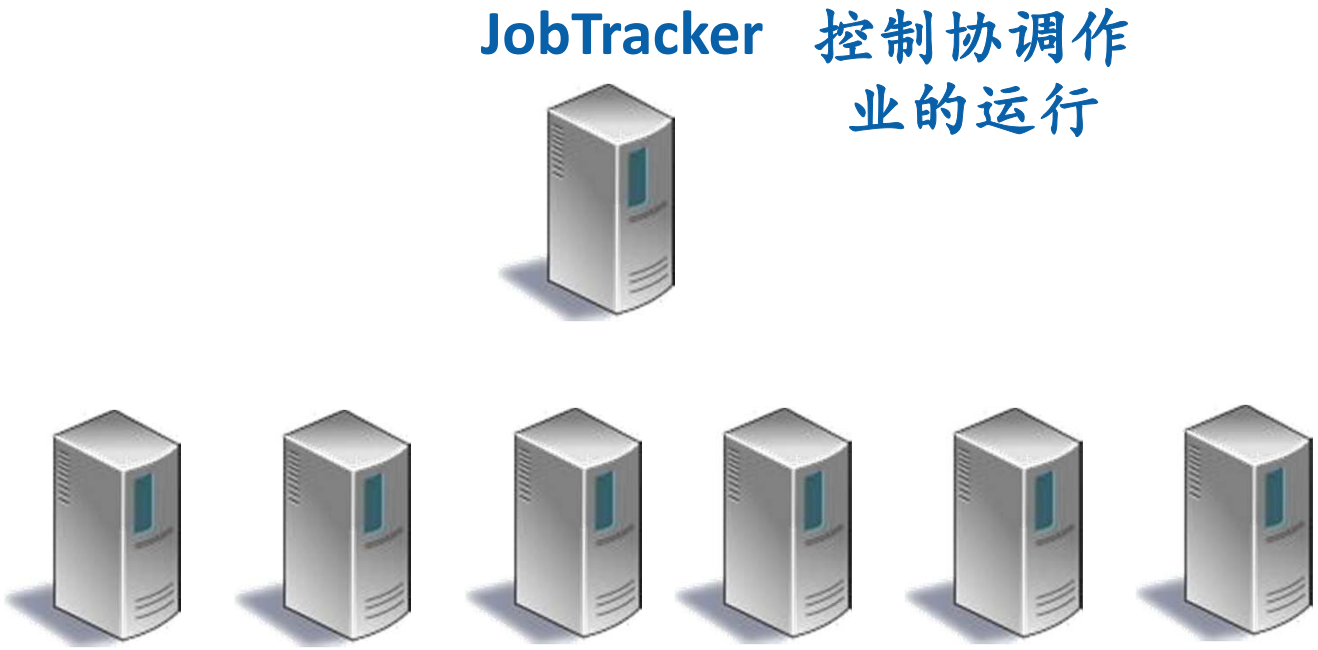

- 注意：JobTracker, TaskTracker, Name Node, Data Node都是进程，所以可以在一台机器上同时运行JobTracker/Name Node, TaskTracker/Data Node
- Hadoop 2.x采用YARN代替了JobTracker，但功能大同小异

MR运行：提交作业

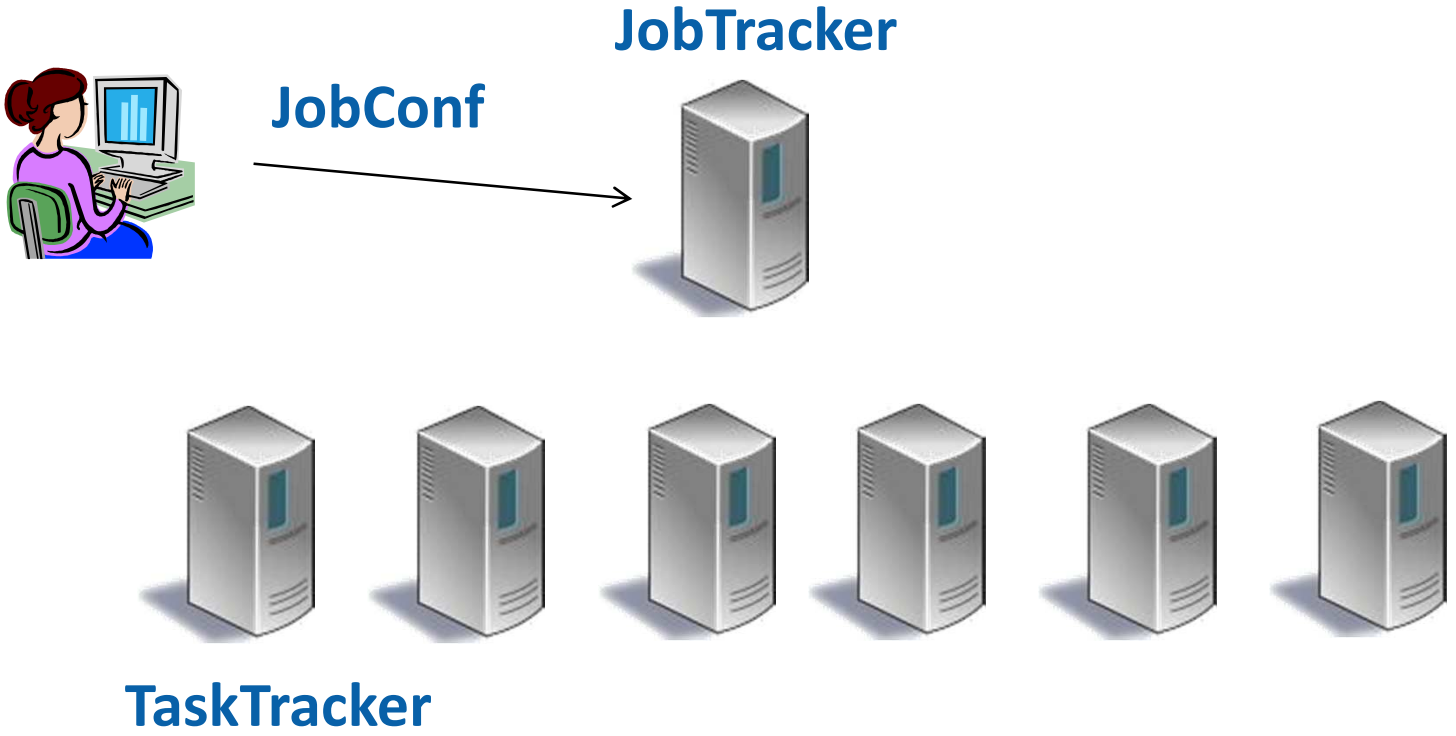

- 包括Map函数、Reduce函数(Jar)、配置信息(例如，几个Mappers，几个Reducers)、输入路径、输出路径等

MR运行：Map Task 读数据

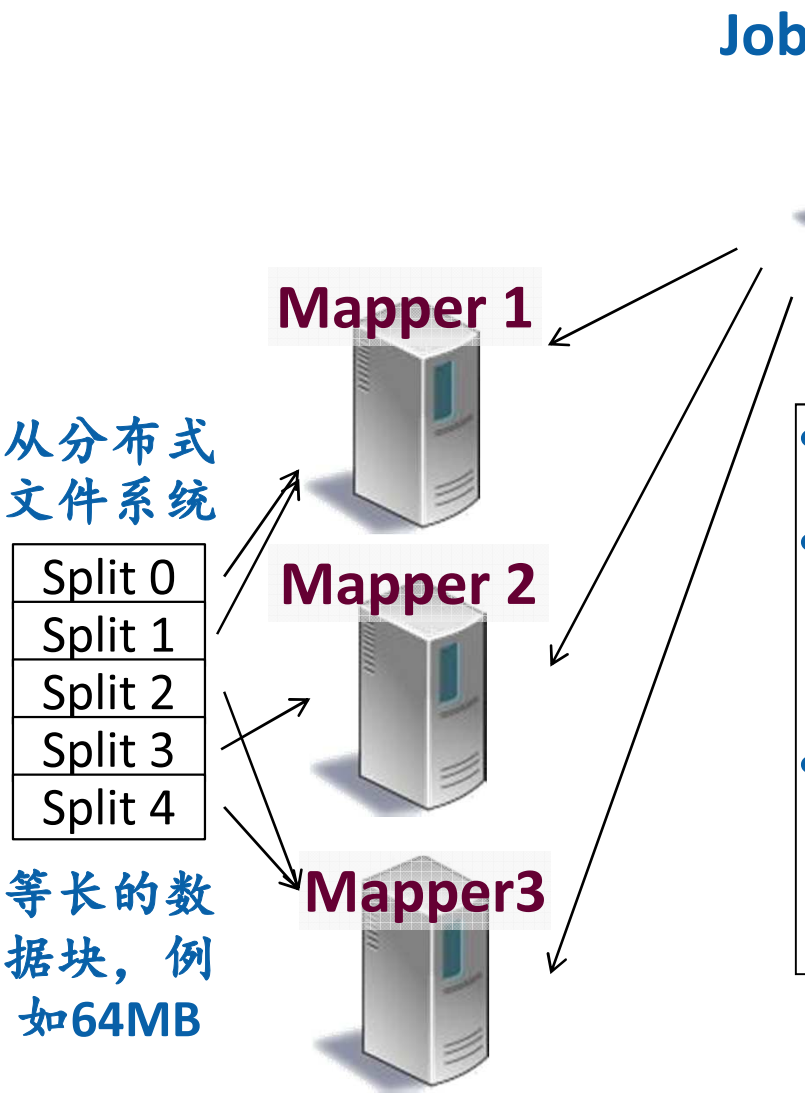

- Split：一个HDFS数据块
- Split 的个数可能多于Mappers个数
  - 每个split对应一个Map Task
  - 每个Mapper可能需要处理多个Task
- 优化：就近处理
  - JobTracker尽量Mapper处理本机data node存储的split，从而减少网络数据传输的开销

MR运行：Map Task 读数据

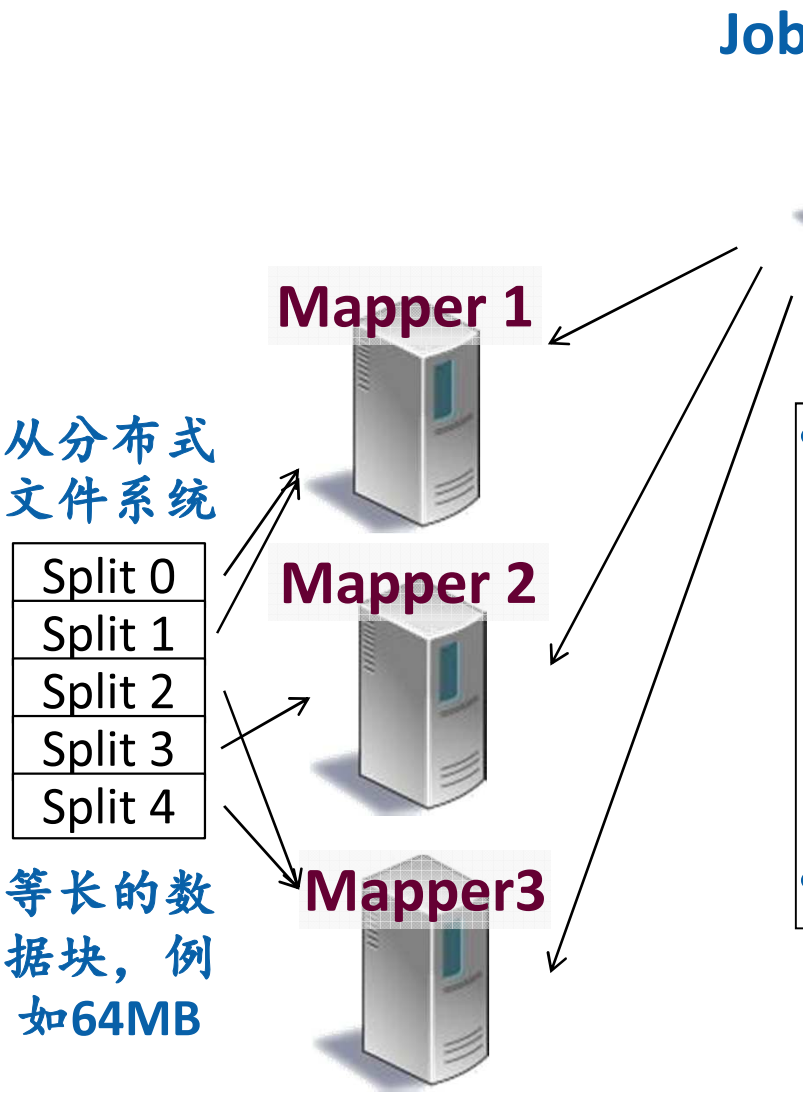

- InputFormat
  - Hadoop提供TextInputFormat，KeyValueInputFormat，SequenceFileInputFormat
  - 如何从提供的输入路径获得数据
  - 如何把输入数据分成split
  - 如何将数据分解成<ik, iv>
- 程序员可以编写自己的InputFormat

MR运行：Map Task 执行

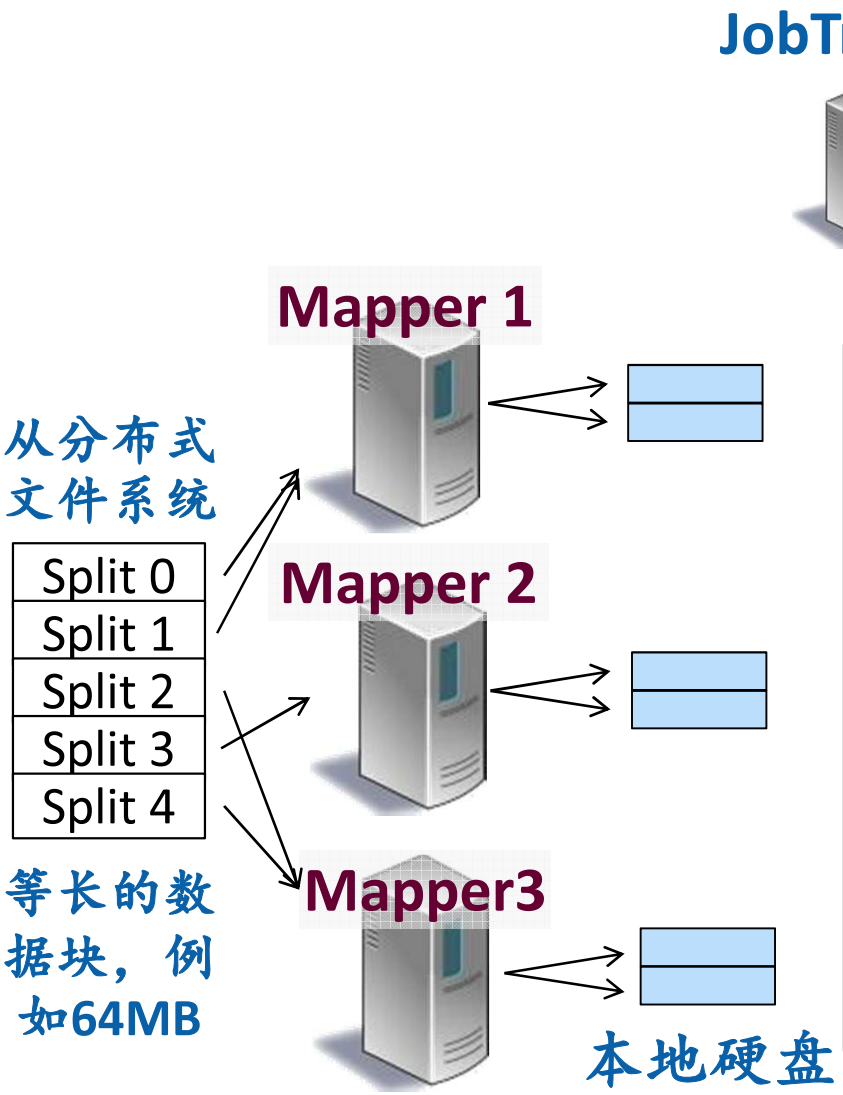

- 对于一个split，Mapper
  - 对每个<ik, iv>调用一次Map函数生成<mk,mv>
  - 对每个mk调用Partitioner计算其对应的Reduce task id
  - 属于同一个Reduce task的<mk,mv>存储于同一个文件，放在本地硬盘上
  - 每个文件按照mk自小到大排序
- Partitioner：
  - Hadoop默认使用HashPartitioner
    Reduce task id = hash(mk) % ReduceTaskNumber
  - 程序员可以编写自己的Partitioner

MR运行：Shuffle

- Reducer从每个Map task传输中间结果文件
  - 每个文件本身已经排好序了
- 对多个结果文件进行归并，从而实现group by

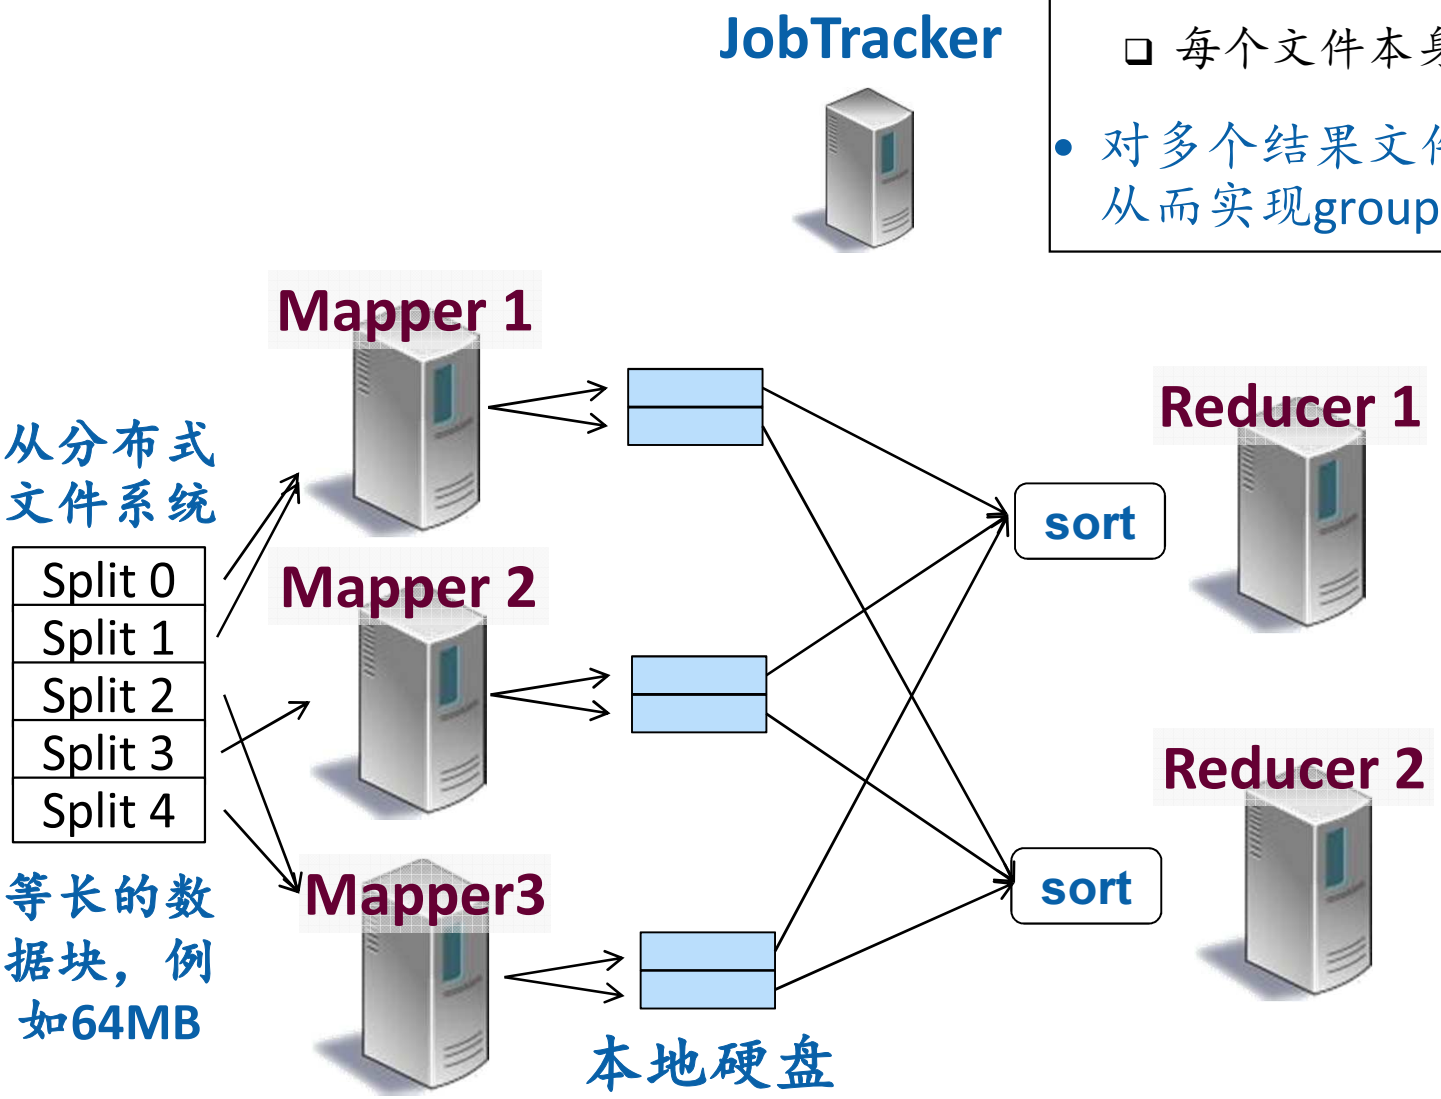

MR运行：Reduce

- 对于每个<mk,{mv}>调用一次Reduce函数
- 产生的<ok, ov>写入输出文件
- OutputFormat
- 每个Reduce task 产生一个单独的文件

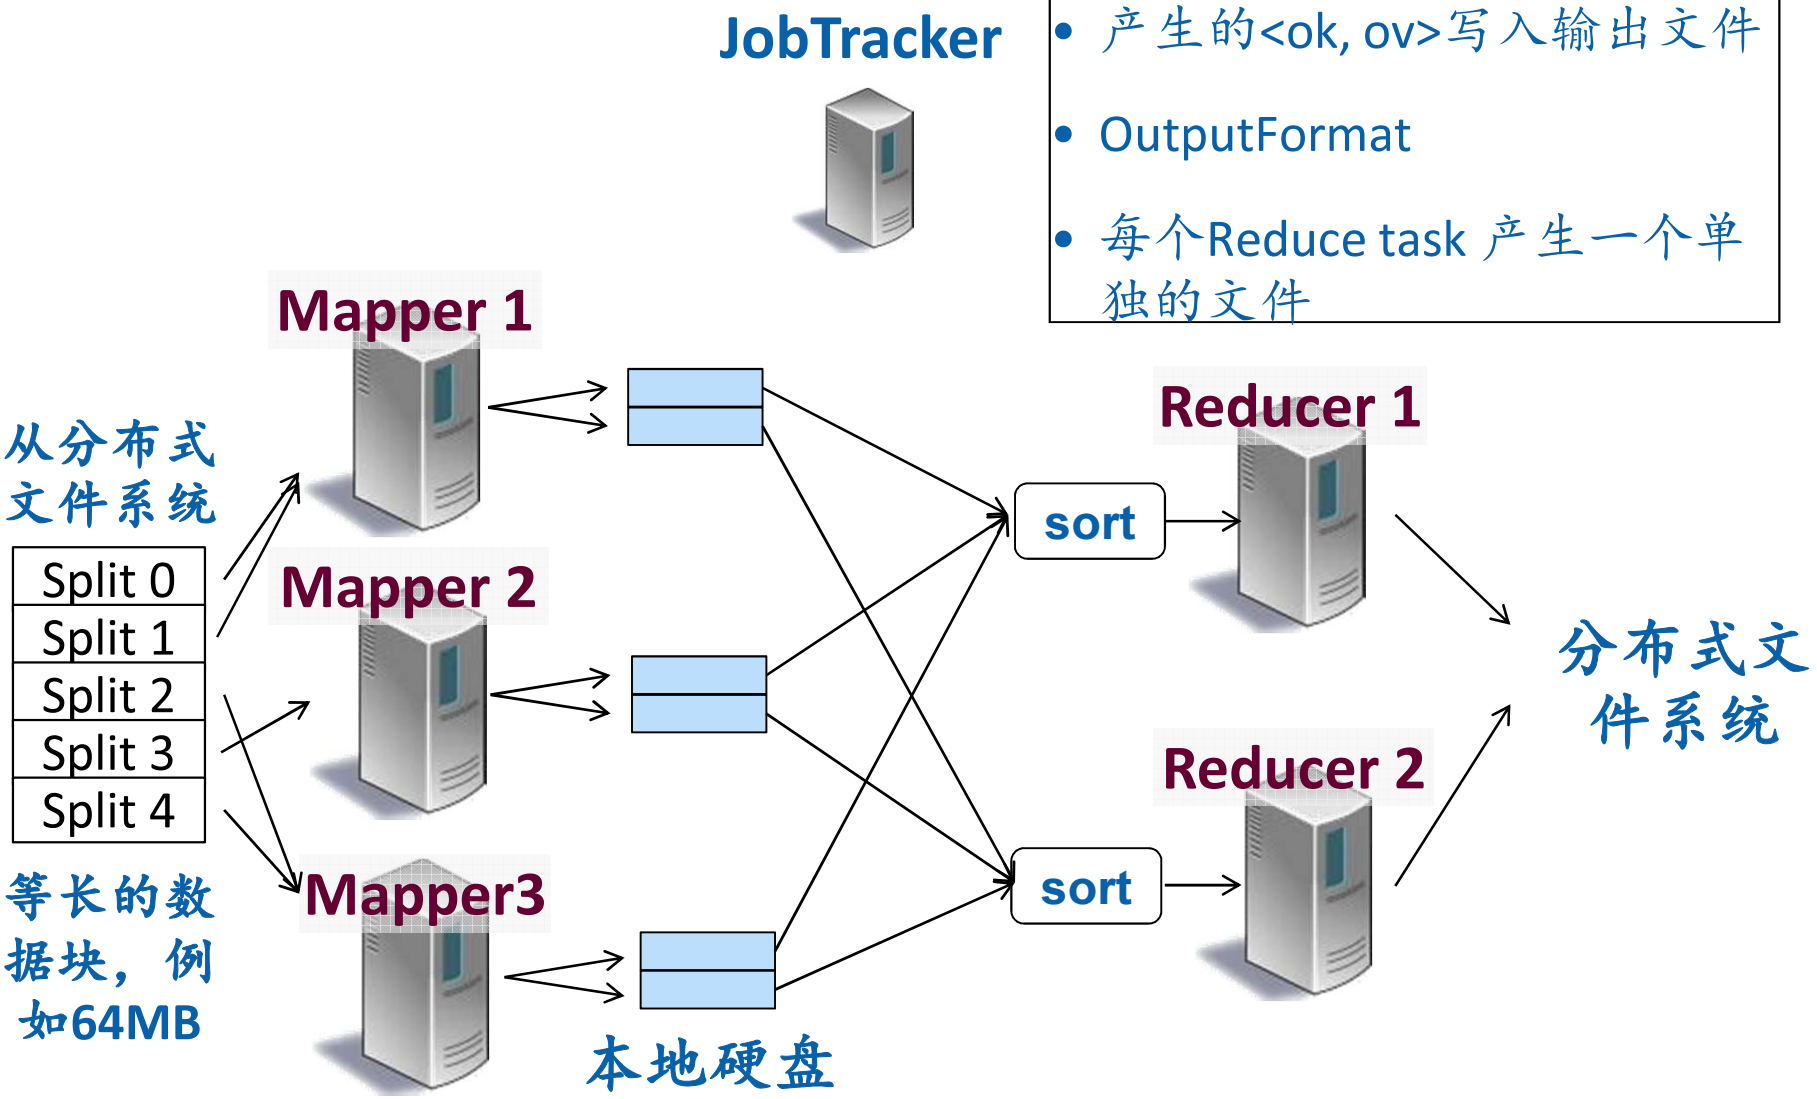

Combiner

- Combiner = partial reducer
  - Combiner(mk, {mv}) ➔ <mk, mv'>
- 回顾word count
  - 传输很多<mk, 1>似乎有些浪费
  - 如果在Mapper一侧，一个mk出现多次，完全可以进行本地的累计，这样只需要传输一个<mk, 本地次数>
  - 这可以用Combiner实现

MR运行：Combiner

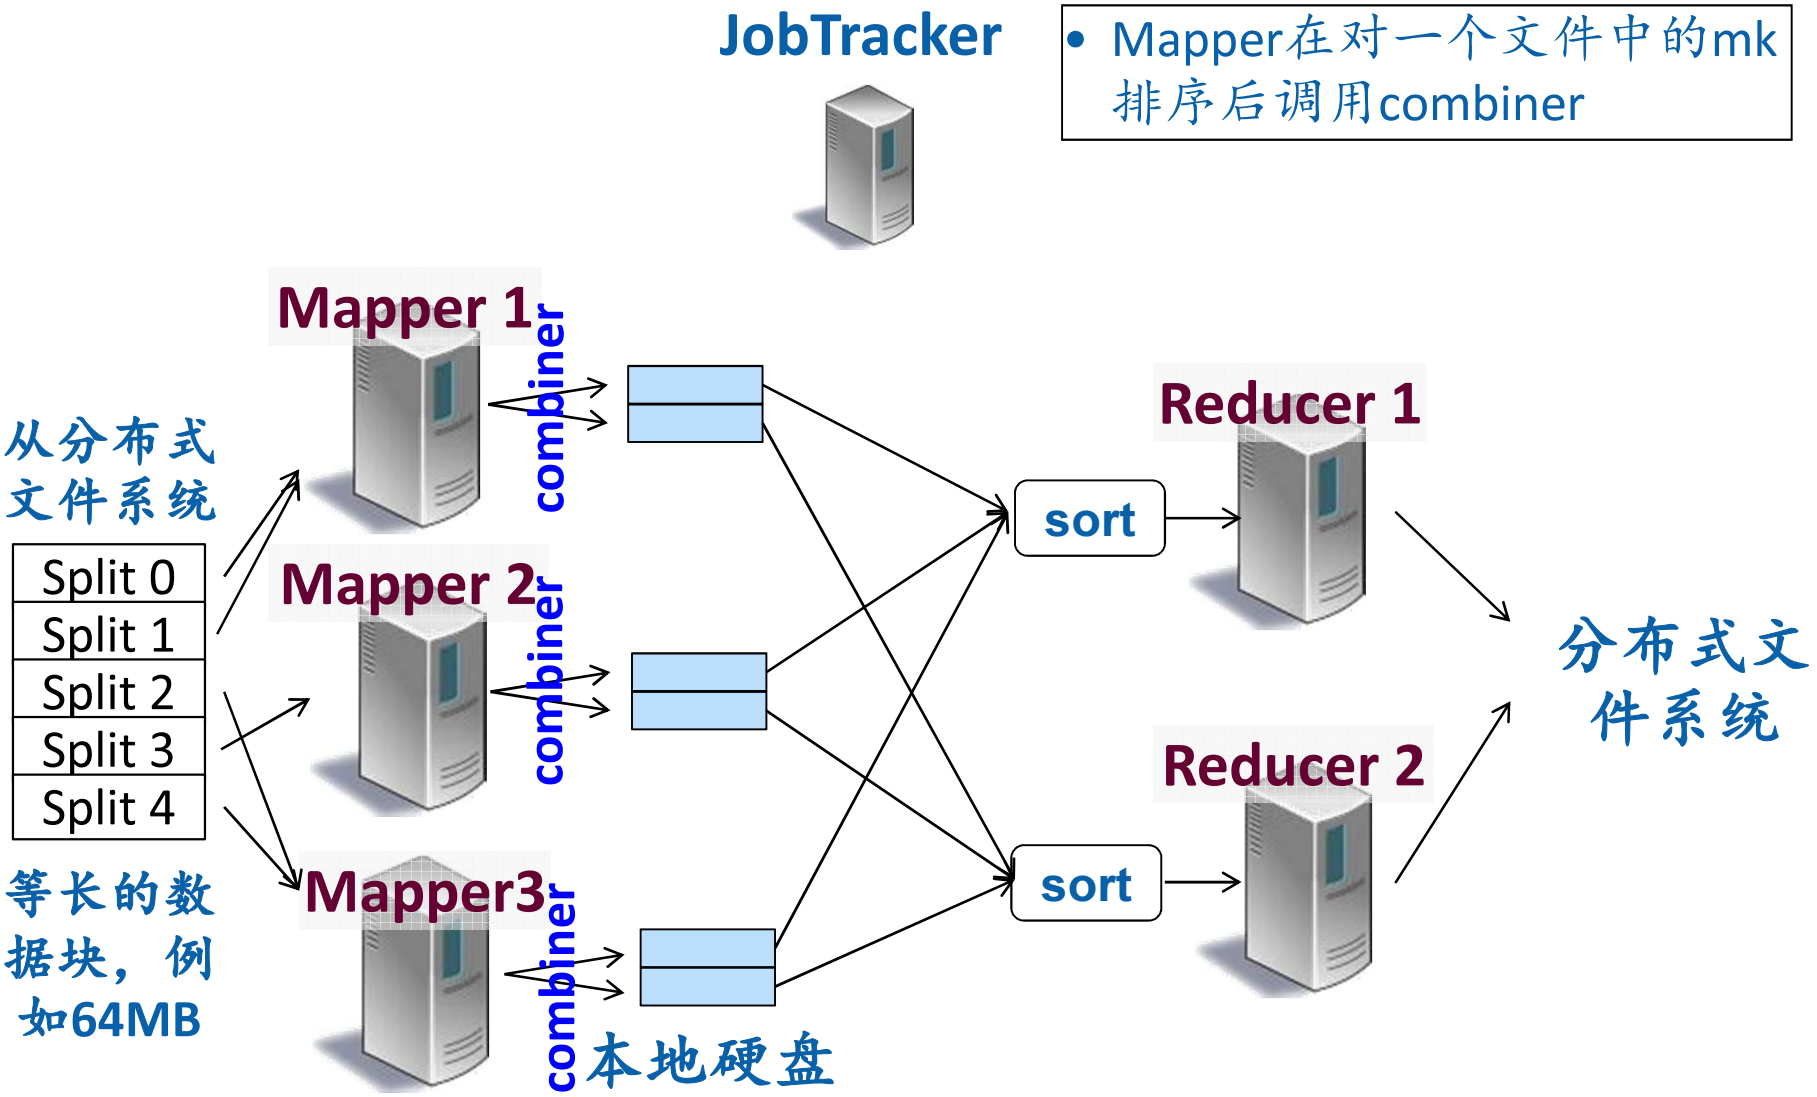

MR: Fault Tolerance (容错)

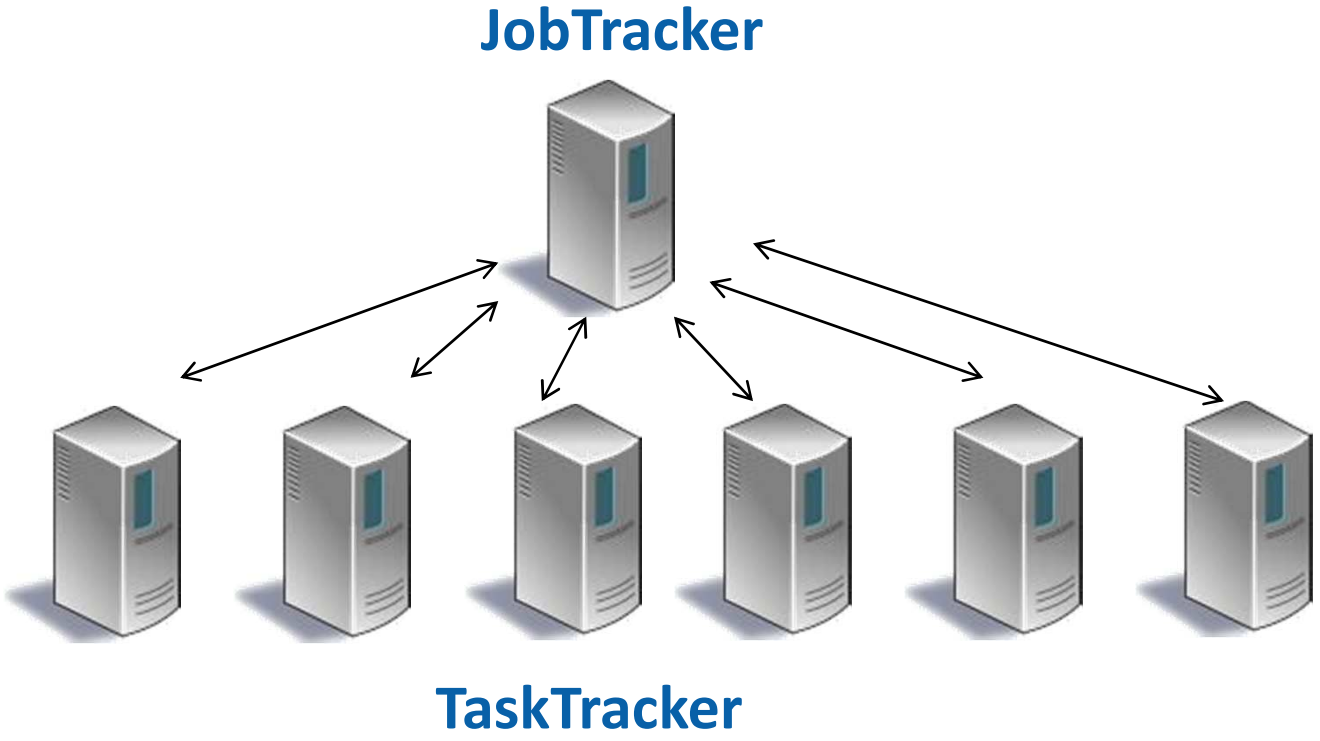

- HeartBeat(心跳)消息
  - 定期发送，向JobTracker汇报进度
- JobTracker可以及时发现不响应的机器或速度非常慢的机器
  - 这些异常机器被称作Stragglers

MR: Fault Tolerance (容错)

- 一旦发现Straggler
  - JobTracker就将它需要做的工作分配给另一个worker
- Straggler是Mapper，将所对应的splits分配给其它的Mapper
  - 输入数据是分布式文件，所以不需要特殊处理
  - 通知所有的Reducer这些splits的新对应Mapper
  - Shuffle时从新对应的Mapper传输数据
- Stragger是Reducer，在另一个TaskTracker执行这个Reducer
  - 这个Reducer需要重新从Mappers传输数据
  - 注意：因为Mapper的输出是在本地文件中的，所以可以多次传输

典型算法

- Grep
- Sorting
- Join

举例：Grep (找到符合特定模式的文本)

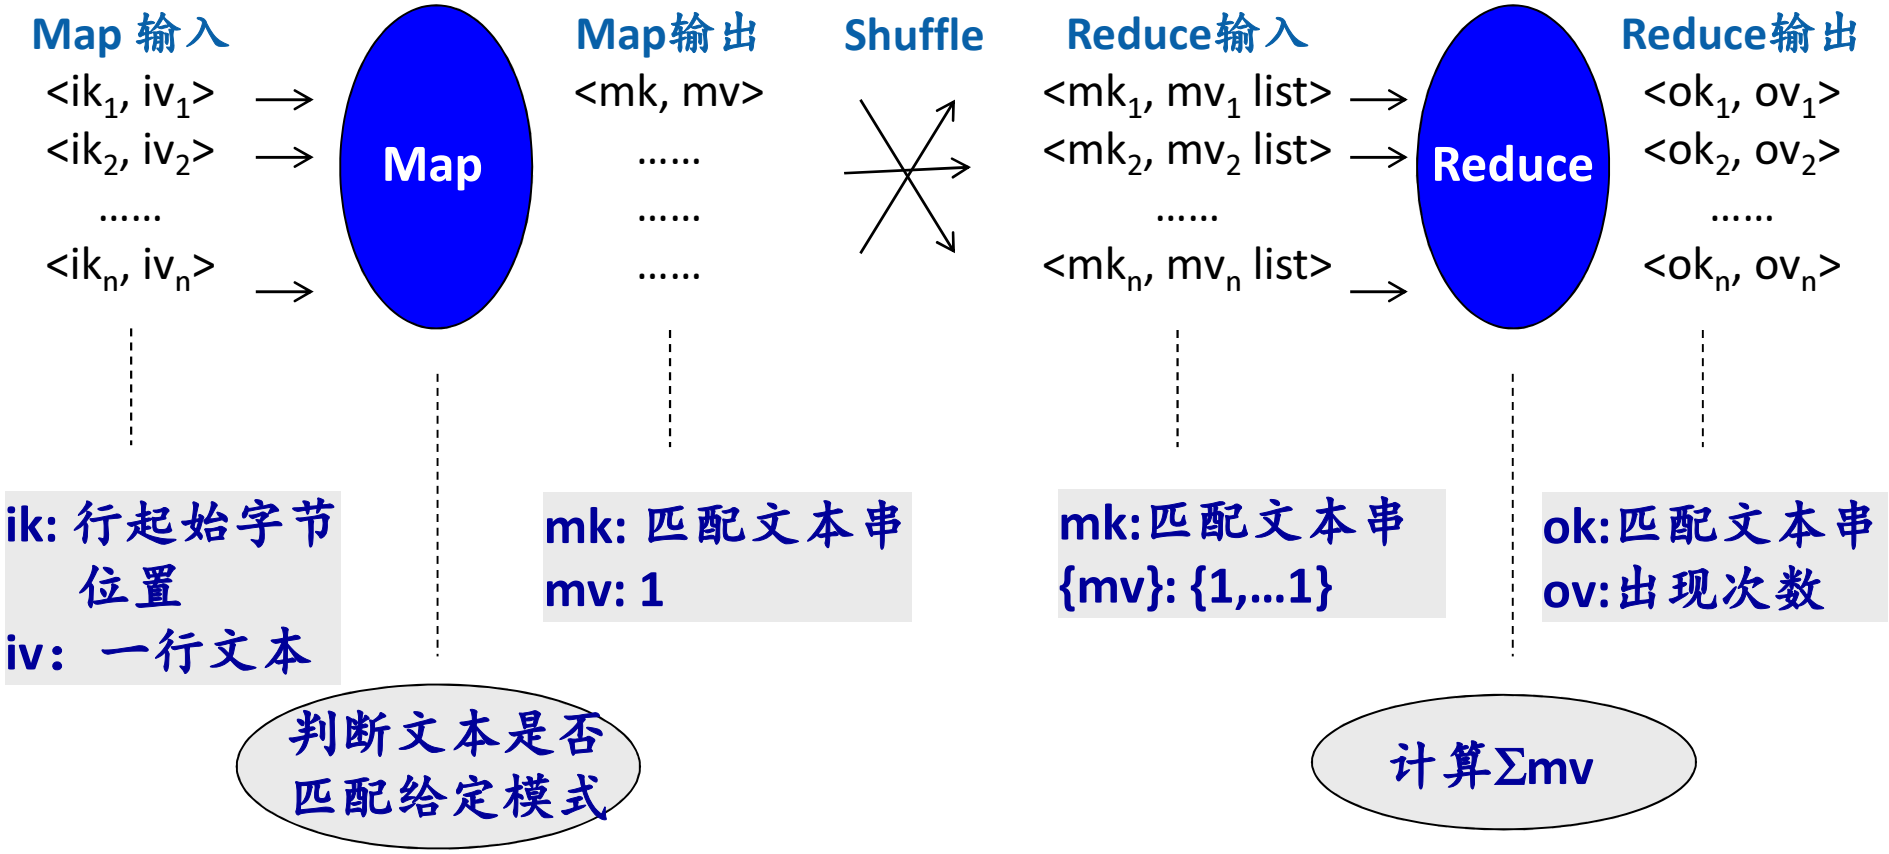

与word count类似

举例： Sorting

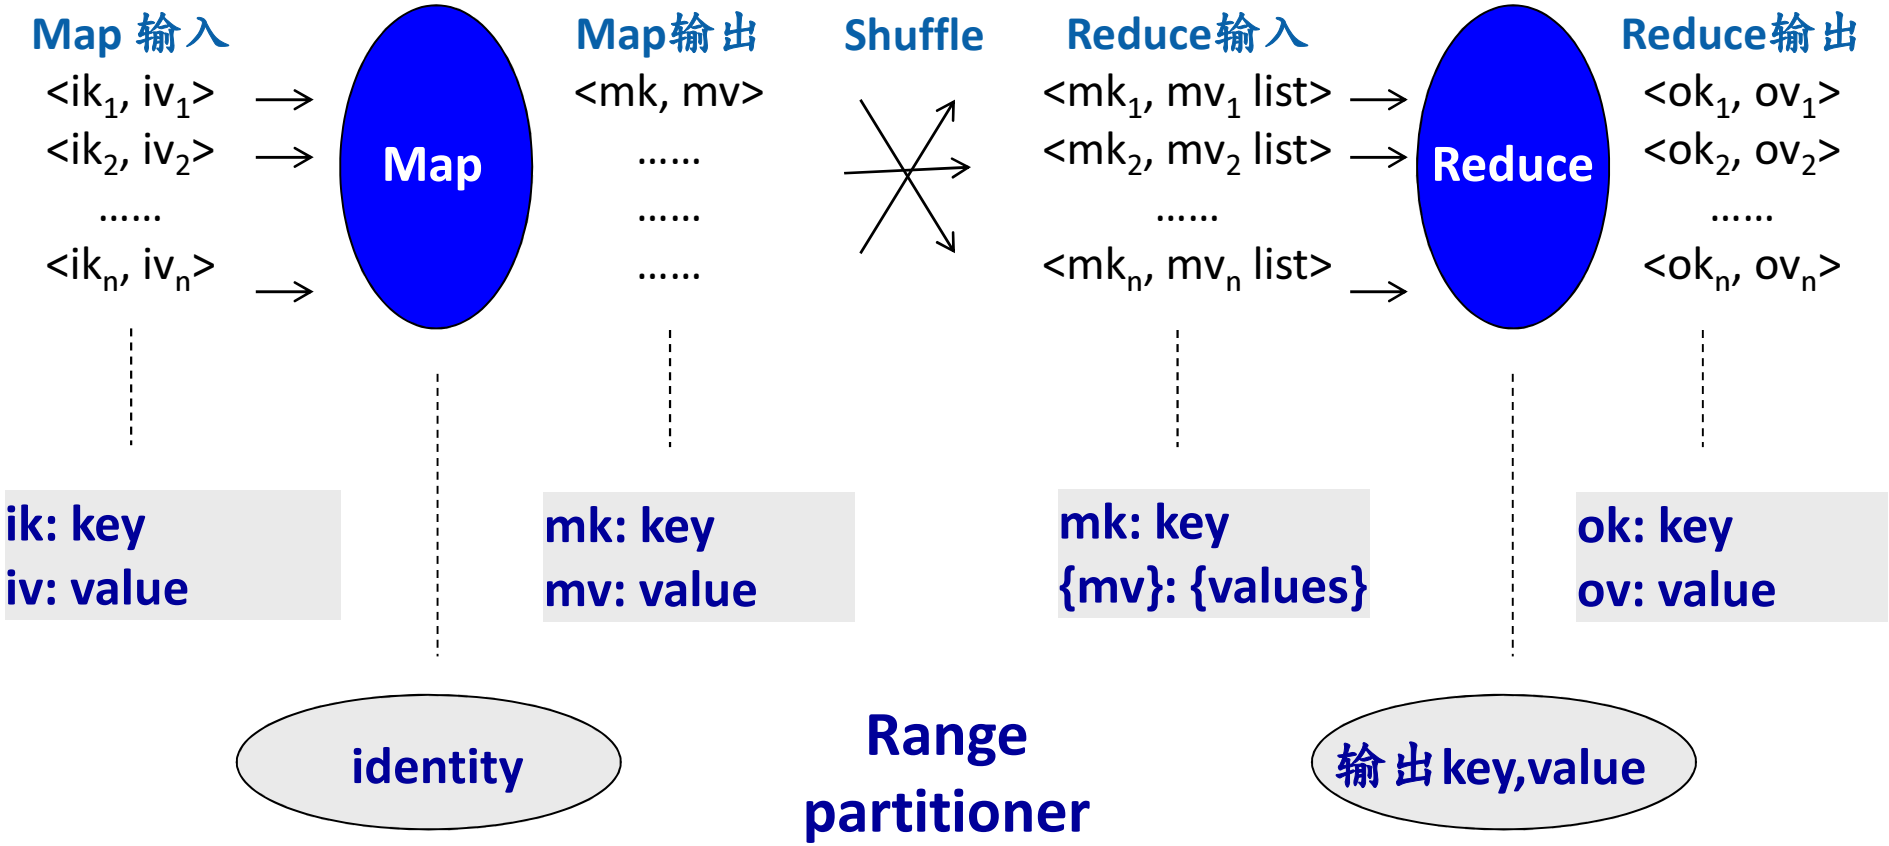

- 利用MapReduce系统的shuffle/sort功能完成sorting
- identity指将输入拷贝到输出

举例： Equi-Join

$R \bowtie_{R.a = S.b} S$

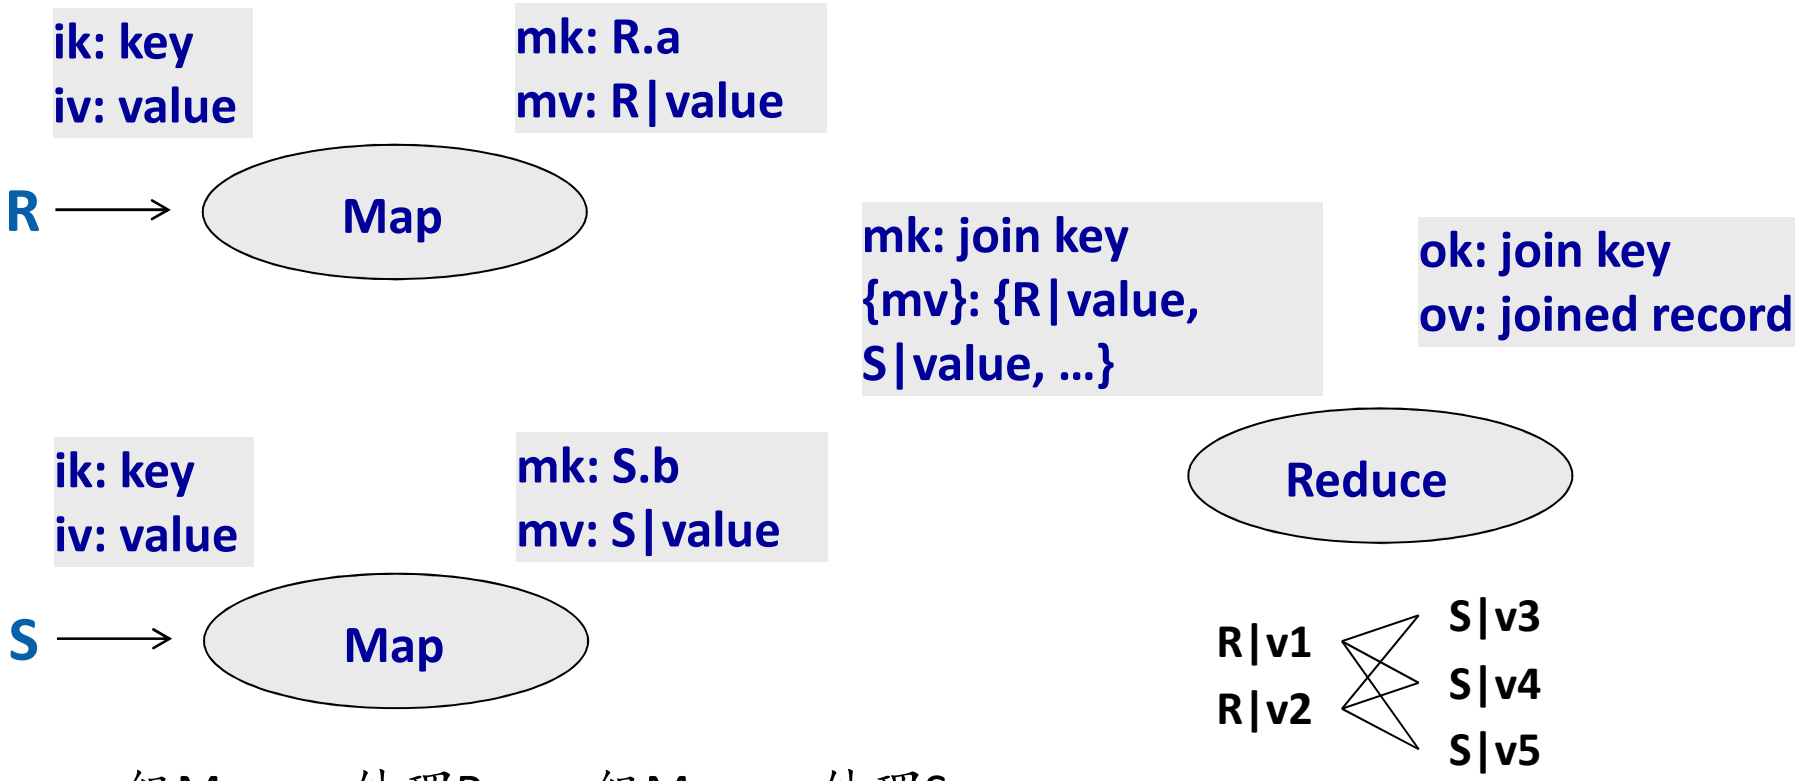

- 一组Mapper处理R，一组Mapper处理S
- 利用shuffle/group by把匹配的record放到一起
- Reduce调用时，{mv}包含对应同一个join key的所有匹配的R和S记录，于是产生每一对R记录和S记录的组合（笛卡尔积），并输出
- 需要传输整个R与S会产生比较大的代价

Microsoft Dryad

- Dryad是对MapReduce模型的一种扩展
  - 组成单元不仅是Map和Reduce，可以是多种节点
  - 节点之间形成一个有向无环图DAG(Directed Acyclic Graph)，以表达所需要的计算
  - 节点之间的数据传输模式更加多样
    - 可以是类似Map/Reduce中的shuffle
    - 也可以是直接1:1、1:多、多:1传输
  - 比MapReduce更加灵活，但也更复杂
    - 需要程序员规定计算的DAG

- Microsoft内部云计算系统Cosmos基于Dryad

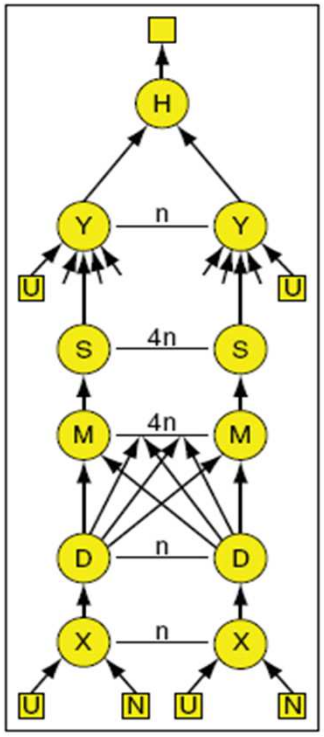

Dryad paper [Eurosys'07]

小结

- MapReduce/Hadoop
  - 编程模型
  - 系统实现
  - 典型算法
- Microsoft Dryad